Chap 2. 머신러닝 프로젝트 처음부터 끝까지

Seolyoung Jeong, Ph.D.

경북대학교 IT 대학

가상의 프로젝트 진행

2.2 큰그림 보기
- 2.2.1 문제정의
- 2.2.2 성능 측정 지표 선택
- 2.2.3 가정 검사

2.3 데이터 가져오기
- 2.3.1 작업 환경 만들기
- 2.3.2 데이터 다운로드
- 2.3.3 데이터 구조 훑어보기
- 2.3.4 테스트 세트 만들기

2.4 데이터 탐색 및 시각화
- 2.4.1 지리적 데이터 시각화
- 2.4.2 상관관계 조사
- 2.4.3 특성 조합으로 실험

2.5 데이터 준비
- 2.5.1 데이터 정제
- 2.5.2 텍스트와 범주형 특성 다루기
- 2.5.3 나만의 변환기
- 2.5.4 특성 스케일링
- 2.5.5 변환 파이프라인

2.6 모델 선택 및 훈련
- 2.6.1 훈련 세트에서 훈련하고 평가하기
- 2.6.2 교차 검증을 사용한 평가

2.7 모델 세부 튜닝
- 2.7.1 그리드 탐색
- 2.7.2 랜덤 탐색
- 2.7.3 앙상블 방법
- 2.7.4 최상의 모델과 오차 분석
- 2.7.5 테스트 세트로 시스템 평가하기

◆ **솔루션 제시**

2.8 시스템 론칭, 모니터링, 유지보수

2.1 실제 데이터로 작업하기

- **공개된 데이터셋**
  - 유명 공개 데이터 저장소
    - UC Irvine Machine Learning Repository (http://archive.ics.uci.edu/ml/)
    - Kaggle datasets (https://www.kaggle.com/datasets)
    - Amazon's AWS datasets (http://aws.amazon.com/fr/datasets/)
  - 메타 포털
    - http://dataportals.org/
    - http://opendatamonitor.eu/
    - http://quandl.com/
  - 인기 공개 데이터 저장소 리스트
    - Wikipedia's list of Machine Learning datasets (https://goo.gl/SJHN2k)
    - Quora.com question (http://goo.gl/zDR78y)
    - Datasets subreddit (https://www.reddit.com/r/datasets)

2.2 큰그림 보기

- 프로젝트 목적 (주택회사)
  - 캘리포니아 주택 가격 모델 작성
  - 다른 데이터가 주어졌을 때 구역의 중간 주택 가격 예측

- 캘리포니아 인구조사 데이터 사용하여 모델 작성
  - 캘리포니아 블록 그룹별 (600~3,000명 인구)
  - 인구, 중간 소득, 중간 주택 가격 포함

그림 2-1 캘리포니아 주택 가격

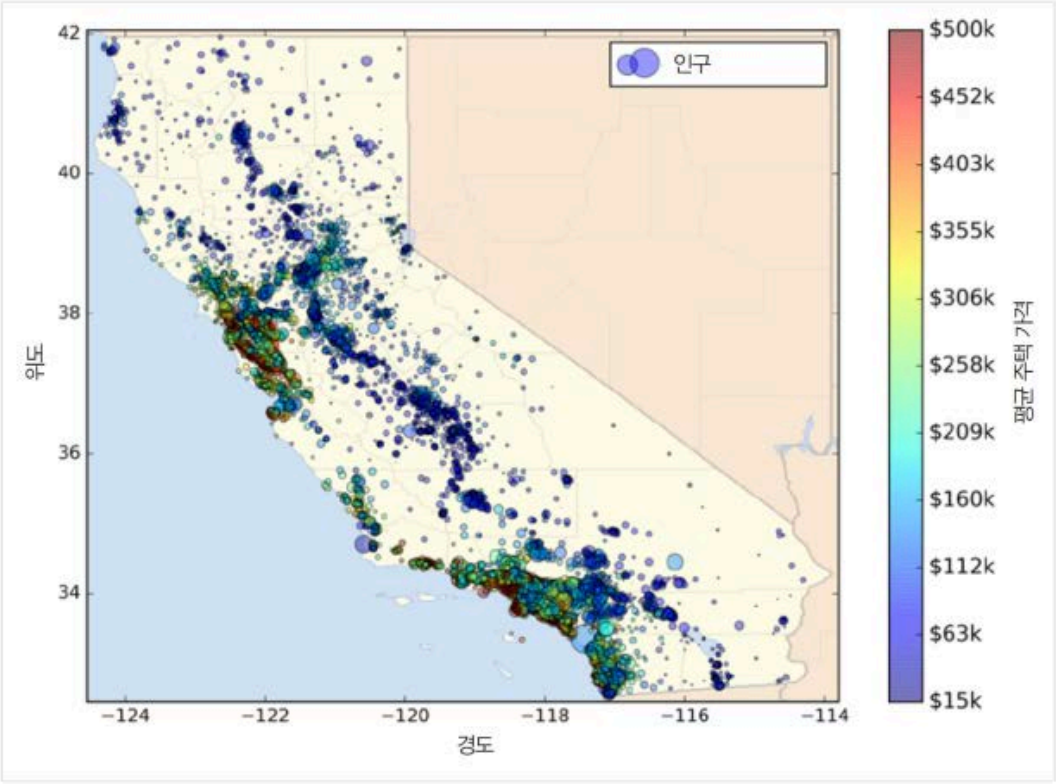

2.2.1 문제 정의 - 비지니스 목적

- **비지니스 목적 파악**
  - 시스템 구성, 알고리즘, 측정 지표, 튜닝 시간 결정

- **비지니스 목적 예) 중간 주택 가격 예측 출력 → 투자 결정 머신러닝 시스템 입력**

그림 2-2 부동산 투자를 위한 머신러닝 파이프라인

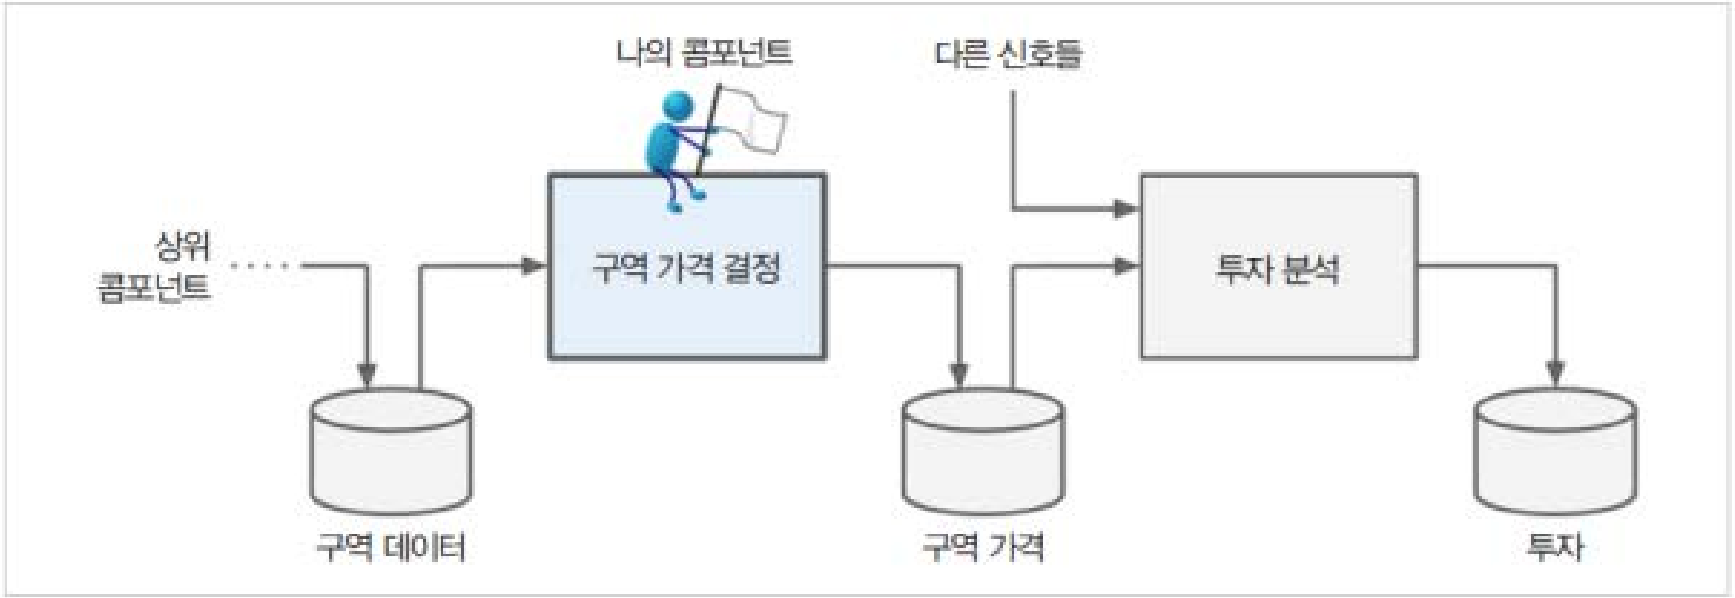

2.2.1 문제 정의

- **현재 솔루션?**
  - 전문가가 수동으로 추정 (10%이상 오류)

- **문제 정의**
  - 지도/비지도/강화학습 ?
  - 분류/회귀학습 ?
  - 배치/온라인학습 ?

  - 레이블된 샘플 있음 → 지도학습
  - 값을 예측 → 회귀학습 (여러 특성 : multivariate regression)
    - 구역의 인구, 중간 소득 특성을 사용
    - 1장 예시: 1인당 GDP 특성 사용 삶의 만족도 예측 (univariate regression)
  - 오프라인, 비교적 느리고, 크지 않은 데이터 → 배치학습

2.2.2 성능 측정 지표

- **전형적인 회귀문제 성능 지표**
  - 평균 제곱근 오차 (Root Mean Square Error : RMSE)
    - 오차가 커질 수록 RMSE 값은 커짐 (예측에 많은 오류가 있음)

$$\mathrm{RMSE}(\boldsymbol{X}, h) = \sqrt{\frac{1}{m}\sum_{i=1}^{m}\left(h\left(\boldsymbol{x}^{(i)}\right) - y^{(i)}\right)^2}$$

  - 평균 절대 오차 (Mean Absolute Error) , 평균 절대 편차
    - 이상치로 보이는 경우가 많은 경우 사용

$$\mathrm{MAE}(\boldsymbol{X}, h) = \frac{1}{m}\sum_{i=1}^{m}\left|h\left(\boldsymbol{x}^{(i)}\right) - y^{(i)}\right|$$

  - $\mathbf{X}$: 데이터셋에 있는 모든 샘플의 모든 특성값을 포함하는 행렬
  - h : 시스템의 예측 함수 (가설 : hypothesis)
  - m : 데이터셋에 있는 샘플 수
  - $x^{(i)}$: 데이터셋에 있는 i번째 샘플의 전체 특성값 벡터
  - $y^{(i)}$: 해당 샘플의 기대 출력값 (레이블)
  - $\hat{y}^{(i)} = h(x^{(i)})$: 샘플 $\mathbf{x}^{(i)}$에 대한 예측함수(h)에 의한 예측값

2.2.2 성능 측정 지표

- **예측값과 타깃값 사이의 거리를 재는 방법 (norm)**
  - Euclidian norm : RMSE
  - Manhattan norm : MAE

  - 원소가 n개인 벡터 v의 l_k 노름
    - l_0 : 단순히 벡터에 있는 0이 아닌 원소의 수
    - l_∞ : 벡터에서 가장 큰 절댓값

$$\|v\|_k = (|v_0|^k + |v_1|^k + \cdots + |v_n|^k)^{\frac{1}{k}}$$

$$\textbf{유클리디안 노름} = l_2\textbf{노름} = \|v\|_2 = \|v\| = \sqrt{m} \times \textbf{RMSE}$$

$$\textbf{맨하탄 노름} = l_1\textbf{노름} = \|v\|_1 = m \times \textbf{MAE}$$

  - k (노름지수)가 클수록 큰 값의 원소에 치우치며 작은 값은 무시
  - RMSE가 MAE보다 이상치에 더 민감
  - 이상치가 매우 드물면 RMSE가 잘 맞아 일반적으로 널리 사용 (예: 종 모양 분포의 양 끝단)

2.2.2 성능 측정 지표 - 표기법

- **어떤 구역의 값**
  - 경도 -118.29, 위도 33.91
  - 주민수 1,416명
  - 중간소득 $38,372

$$\boldsymbol{x}^{(1)} = \begin{pmatrix} -118.29 \\ 33.91 \\ 1,416 \\ 38,372 \end{pmatrix} \qquad y^{(1)} = 156,400$$

  - (레이블) 중간 주택 가격 $156,400

- **데이터셋의 모든 샘플 값** $\boldsymbol{X} = \begin{pmatrix} (\boldsymbol{x}^{(1)})^T \\ (\boldsymbol{x}^{(2)})^T \\ \vdots \\ (\boldsymbol{x}^{(1999)})^T \\ (\boldsymbol{x}^{(2000)})^T \end{pmatrix} = \begin{pmatrix} -118.29 & 33.91 & 1,416 & 38,372 \\ \vdots & \vdots & \vdots & \vdots \end{pmatrix}$

- **하나의 샘플에 대한 예측값** $\hat{y}^{(i)} = h(\boldsymbol{x}^{(i)})$

2.2.3 가정 검사

- **지금까지 만든 가정을 나열하고 검사**

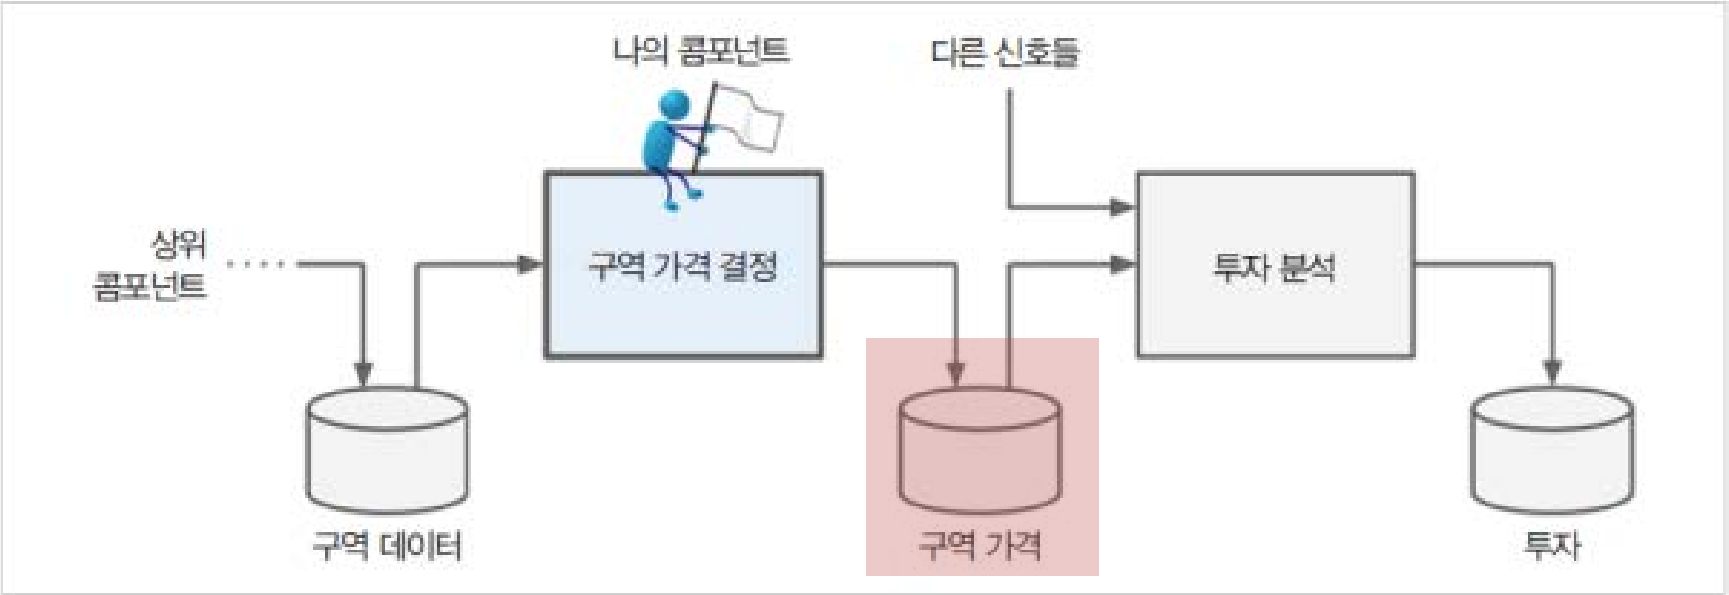

  - 만약, 중간 주택 가격이 아닌 등급(저렴/보통/고가)을 원한다면?
    → 회귀가 아닌, 분류작업이 필요

- **너무 늦게 문제를 발견하지 않도록 주의...**

2.3.1 작업환경 만들기

- **필요한 python package**
  - numpy, pandas, matplotlib
  - jupyter notebook
  - scikit-learn
  - tensorflow
  - ...

- **Anaconda package**
  - 300개 이상 모듈 포함

- **Anaconda 설치 후 업데이트 확인 할 것**
  - Anaconda Prompt

    > conda update scikit-learn

    > conda update pandas

파이썬(Python)

- 1991년 귀도 반 로섬(Gudi Van Rossum)이 발표
- 플랫폼 독립적인 인터프리터 언어이며,
- 객체 지향적, 동적 타이핑 대화형 언어
- 처음 C언어로 구현되었음

Gudi Van Rossum

Python Logo

파이썬은 '피톤'이라는 이름으로 알려진, 고대 그리스 신화에 나오는 거대한 뱀의 이름. 피톤은 Python을 고대 그리스어로 읽은 것이며, 영어를 그대로 읽으면 '파이선'이 됨.
사실, 파이썬이라는 이름은 파이썬을 만든 귀도 반 로섬(Guido van Rossum)이 자신이 좋아하는 영국 코미디 프로인 '몬티 파이선의 날아다니는 서커스(Monty Python's Flying Circus)'에서 따왔다고 함. 물론 여기서의 파이선도 피톤을 의미.

왜 파이썬을 배우는가? 2)

- **Top Programming Languages (2017)**

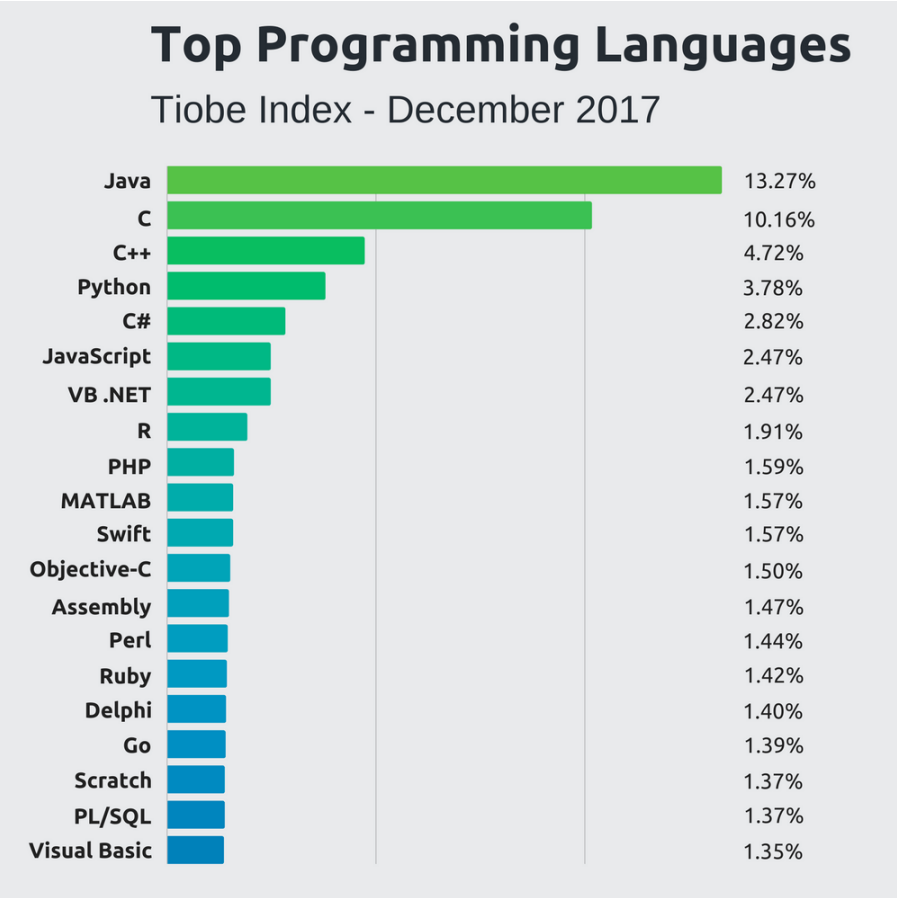

- **Most Pull Requests in GitHub (2017)**
  - GitHub : 오픈소스 프로젝트 사이트

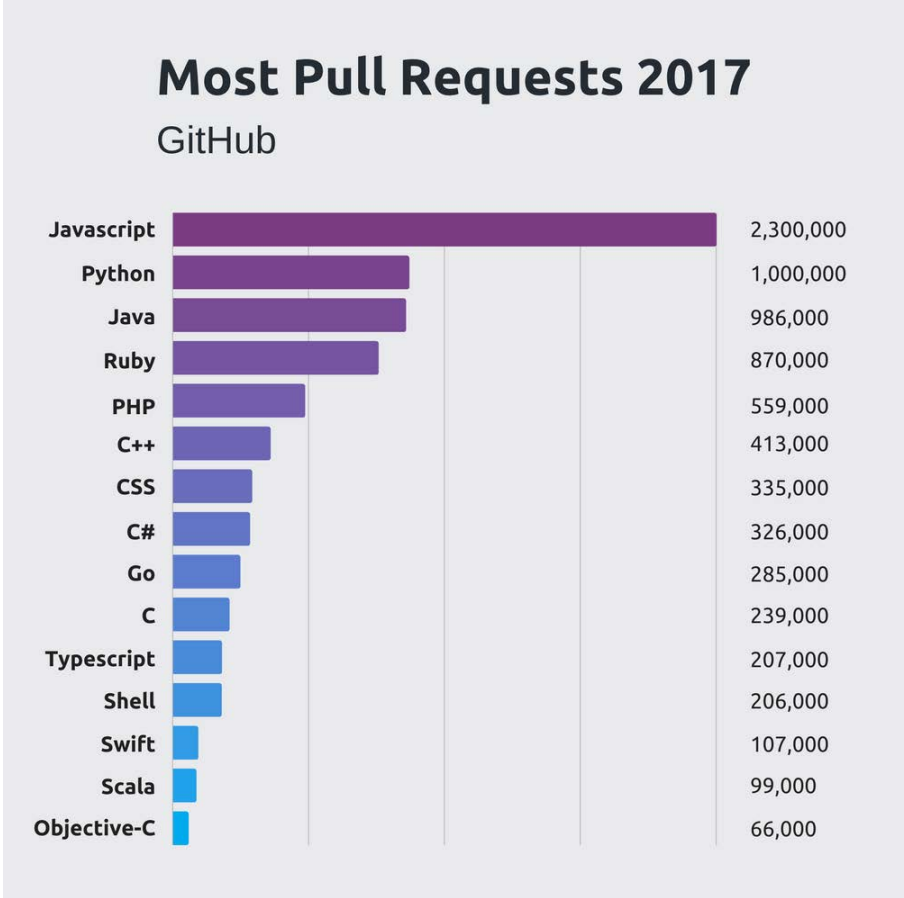

왜 파이썬을 배우는가? 2)

- **History of Programming Language Ratings**

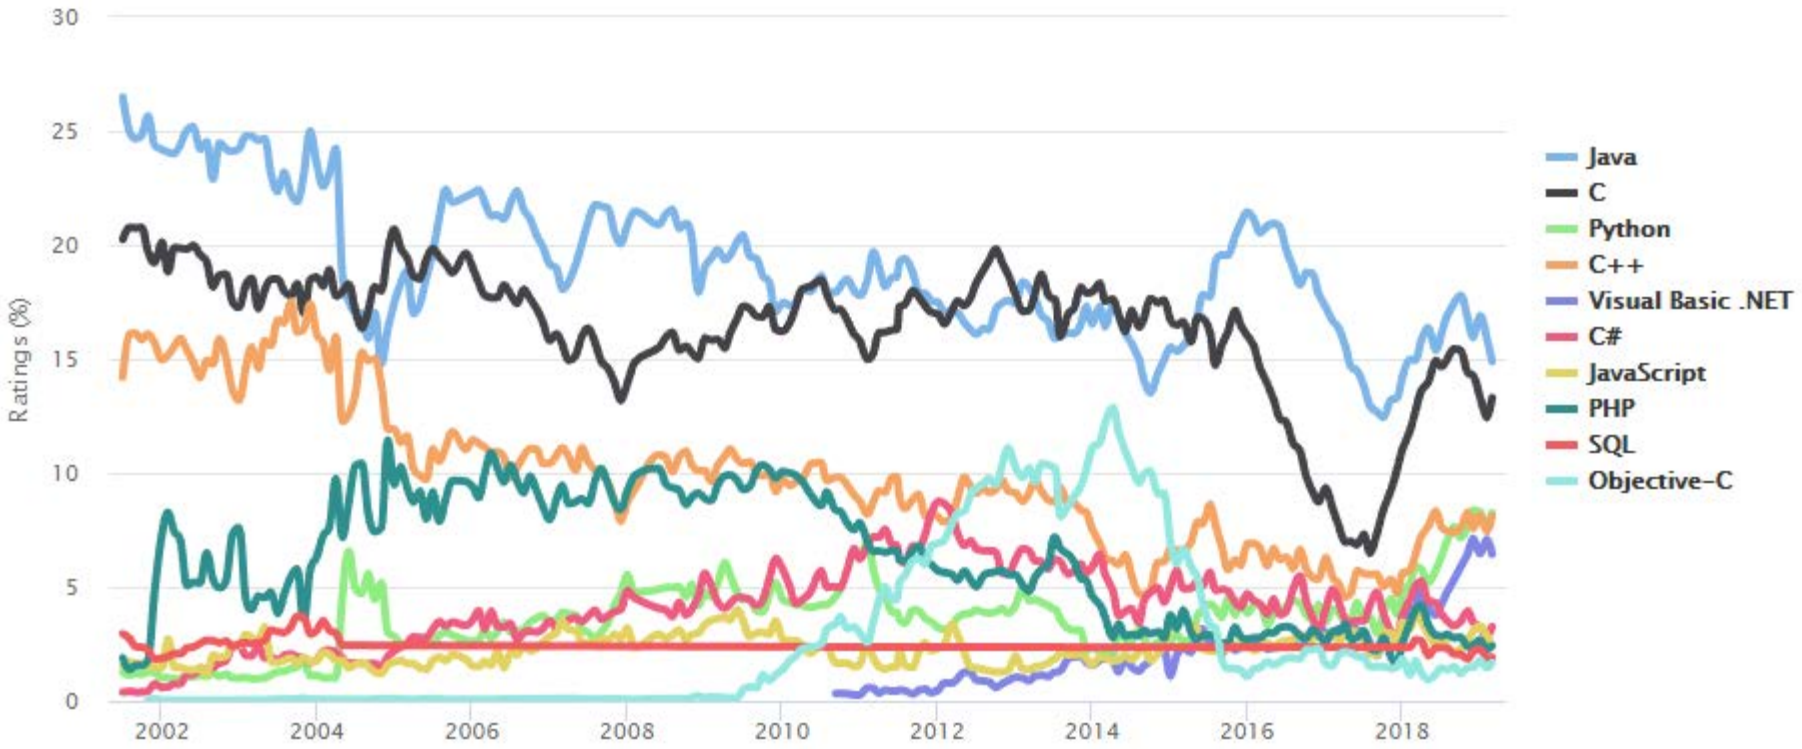

Deep Learning Libraries

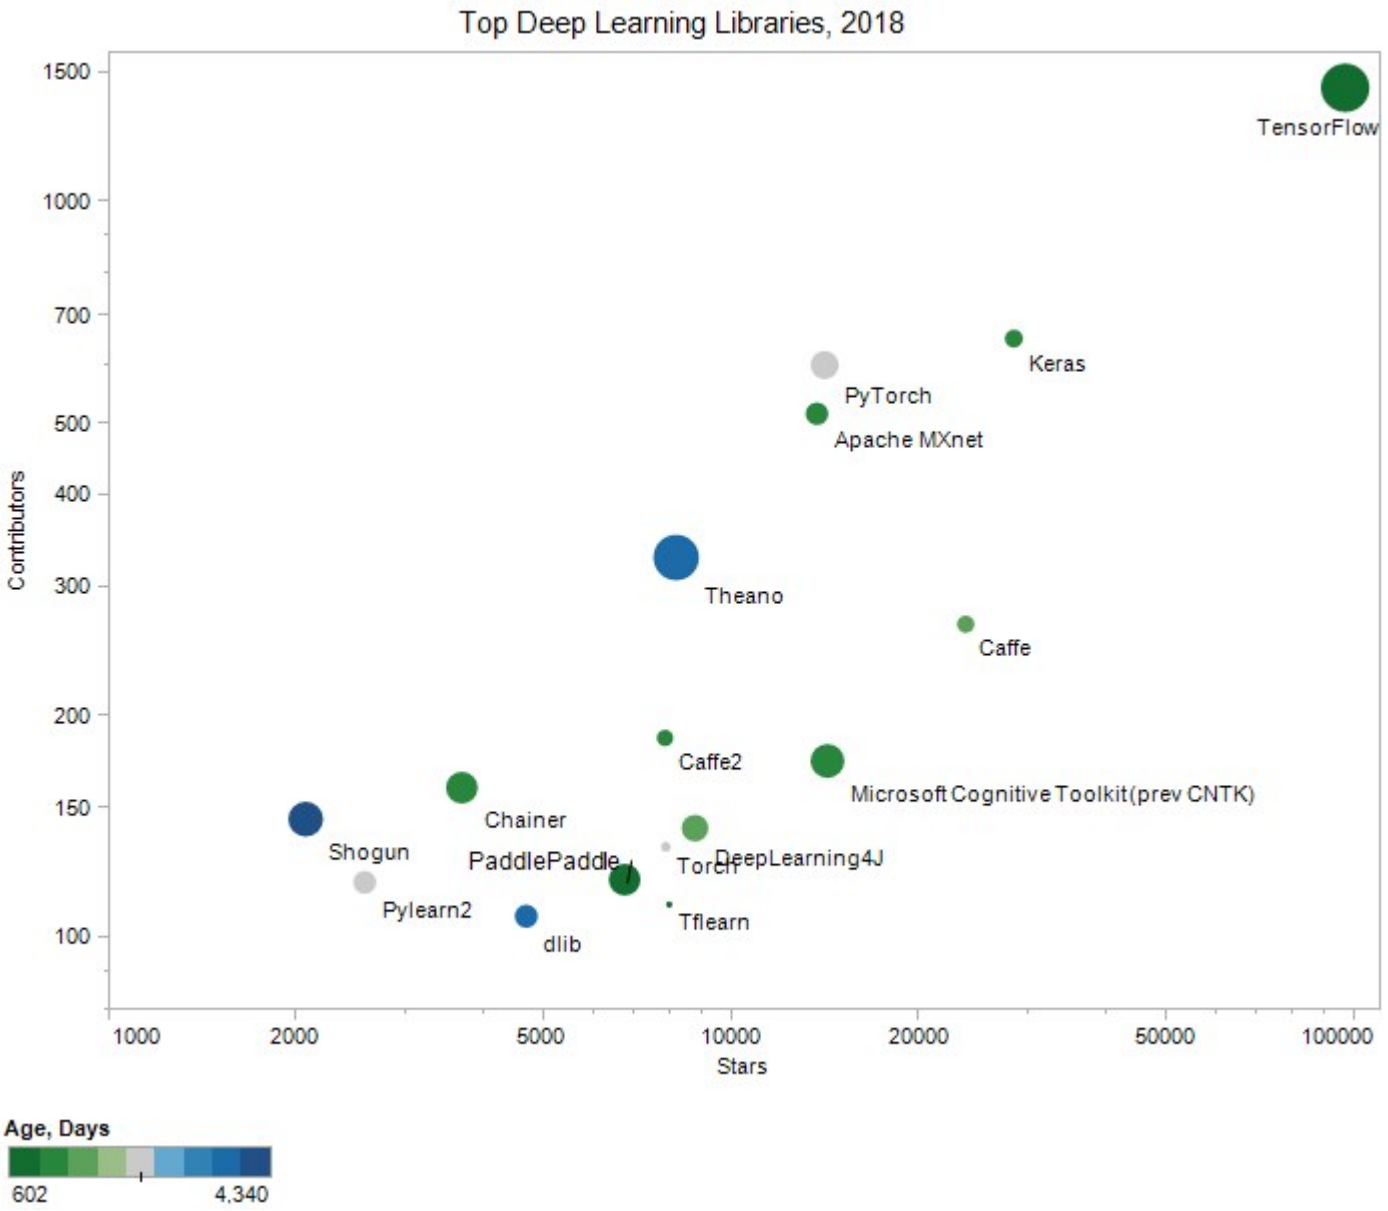

Python AI and Machine Learning projects

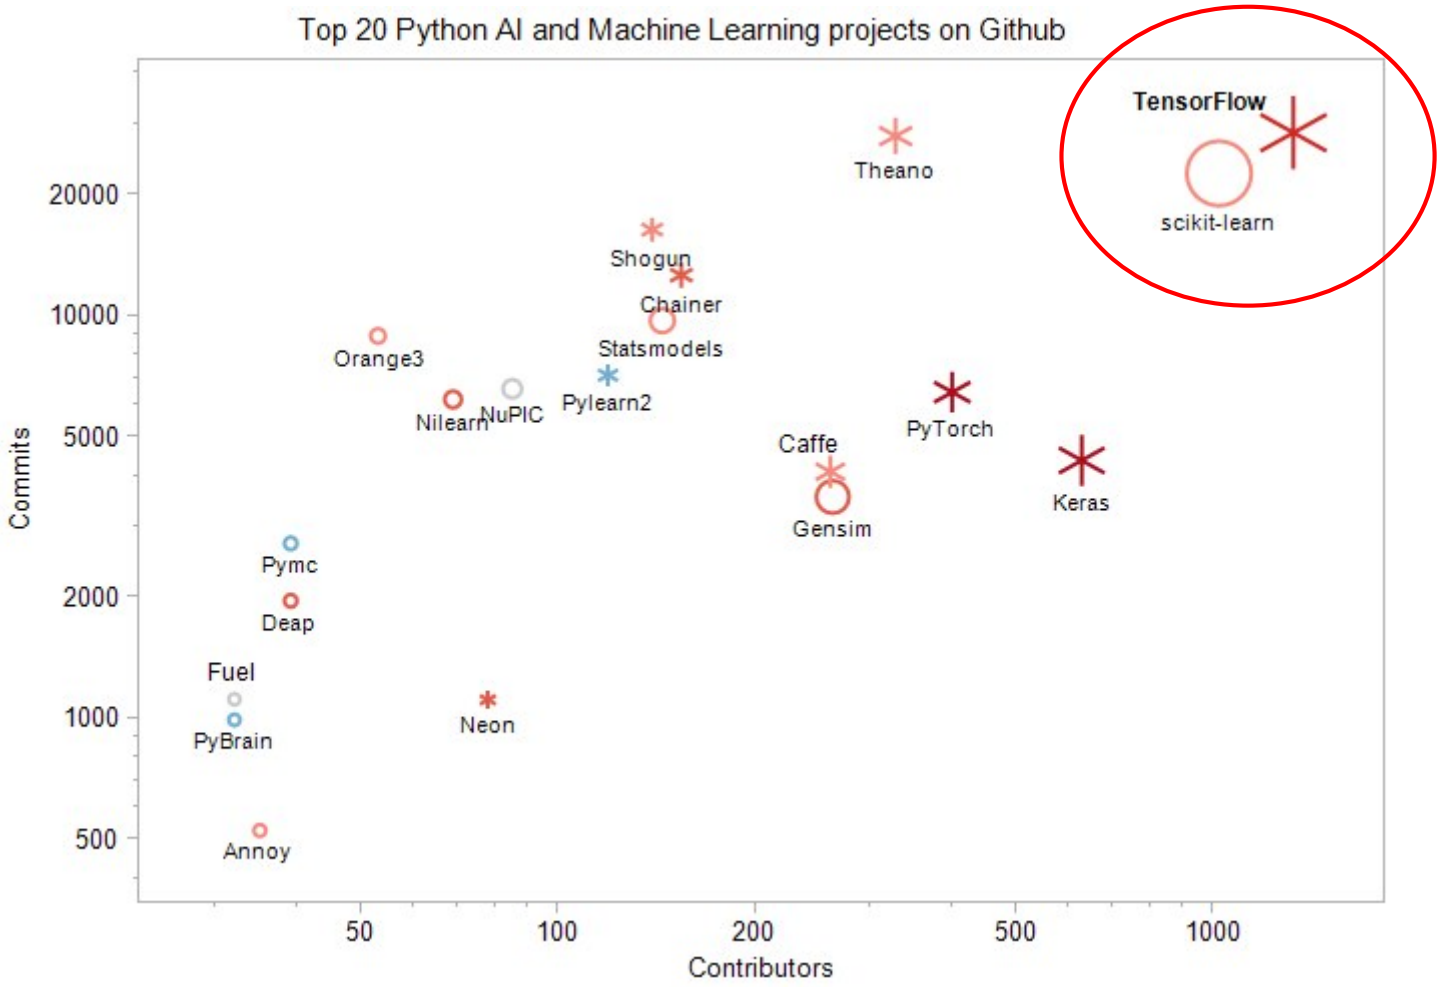

Jupyter Notebook

- **코드, 수식, 시각화 및 설명 텍스트가 포함된 문서를 작성하고 공유 가능**
- **오픈소스 웹 애플리케이션 (웹 브라우저 기반)**
- **데이터 정리, 변환, 수치 시뮬레이션, 통계 모델링, 데이터 시각화, 머신 러닝 등에 사용**
- **장점**
  - 데이터 시각화 용이
  - 코드 공유 용이
  - 실시간 실행 (대화형) 가능
  - 코드 샘플 기록
- **단점**
  - IDE 기능 없음
  - 디버깅, 모듈관리 등을 지원하는 본격적인 파이선 개발 환경은 아님
  - 세션 상태 저장 안됨 : 노트북을 불러올 때마다 코드를 다시 실행해야만 상태 복원 가능

2.3.2 데이터 다운로드

- download/datasets/housing/ 폴더에
- housing.tgz 압축 파일 다운로드
- 압축해제 → housing.csv 파일

In [2]:
```
import os
import tarfile
from six.moves import urllib

DOWNLOAD_ROOT = "https://raw.githubusercontent.com/ageron/handson-ml/master/"
HOUSING_PATH = os.path.join("datasets", "housing")
HOUSING_URL = DOWNLOAD_ROOT + "datasets/housing/housing.tgz"

def fetch_housing_data(housing_url=HOUSING_URL, housing_path=HOUSING_PATH):
    if not os.path.isdir(housing_path):
        os.makedirs(housing_path)
    tgz_path = os.path.join(housing_path, "housing.tgz")
    urllib.request.urlretrieve(housing_url, tgz_path)
    housing_tgz = tarfile.open(tgz_path)
    housing_tgz.extractall(path=housing_path)
    housing_tgz.close()
```

In [3]:
```
fetch_housing_data()
```

pandas로 csv 파일 읽기

- 10개의 특성

In [4]:
```
import pandas as pd

def load_housing_data(housing_path=HOUSING_PATH):
    csv_path = os.path.join(housing_path, "housing.csv")
    return pd.read_csv(csv_path)
```

In [5]:
```
housing = load_housing_data()
housing.head()
```

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximity
0	-122.23	37.88	41.0	880.0	129.0	322.0	126.0	8.3252	452600.0	NEAR BAY
1	-122.22	37.86	21.0	7099.0	1106.0	2401.0	1138.0	8.3014	358500.0	NEAR BAY
2	-122.24	37.85	52.0	1467.0	190.0	496.0	177.0	7.2574	352100.0	NEAR BAY
3	-122.25	37.85	52.0	1274.0	235.0	558.0	219.0	5.6431	341300.0	NEAR BAY
4	-122.25	37.85	52.0	1627.0	280.0	565.0	259.0	3.8462	342200.0	NEAR BAY

2.3.3 데이터 구조 훑어보기

- **housing.info()**
  - 총 20,640개 샘플
  - total_bedrooms 특성은 20,433개만 널값이 아님 (207개 비어 있음)
  - ocean_proximity 필드 데이터 타입
    - object (문자열), 카테고리 (예: NEAR BAY)

```
In [6]: housing.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 20640 entries, 0 to 20639
Data columns (total 10 columns):
longitude             20640 non-null float64
latitude              20640 non-null float64
housing_median_age    20640 non-null float64
total_rooms           20640 non-null float64
total_bedrooms        20433 non-null float64
population            20640 non-null float64
households            20640 non-null float64
median_income         20640 non-null float64
median_house_value    20640 non-null float64
ocean_proximity       20640 non-null object
dtypes: float64(9), object(1)
memory usage: 1.6+ MB
```

ocean_proximity 필드 내 카테고리 확인

```
In [7]: housing["ocean_proximity"].value_counts()
Out[7]: <1H OCEAN     9136
        INLAND        6551
        NEAR OCEAN    2658
        NEAR BAY      2290
        ISLAND           5
        Name: ocean_proximity, dtype: int64
```

숫자형 특성 요약 정보

```
In [8]: housing.describe()
```

Out[8]:

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value
count	20640.000000	20640.000000	20640.000000	20640.000000	20433.000000	20640.000000	20640.000000	20640.000000	20640.000000
mean	-119.569704	35.631861	28.639486	2635.763081	537.870553	1425.476744	499.539680	3.870671	206855.816909
std	2.003532	2.135952	12.585558	2181.615252	421.385070	1132.462122	382.329753	1.899822	115395.615874
min	-124.350000	32.540000	1.000000	2.000000	1.000000	3.000000	1.000000	0.499900	14999.000000
25%	-121.800000	33.930000	18.000000	1447.750000	296.000000	787.000000	280.000000	2.563400	119600.000000
50%	-118.490000	34.260000	29.000000	2127.000000	435.000000	1166.000000	409.000000	3.534800	179700.000000
75%	-118.010000	37.710000	37.000000	3148.000000	647.000000	1725.000000	605.000000	4.743250	264725.000000
max	-114.310000	41.950000	52.000000	39320.000000	6445.000000	35682.000000	6082.000000	15.000100	500001.000000

matflotlib 히스토그램 그리기

```
In [11]: %matplotlib inline
         import matplotlib.pyplot as plt
         housing.hist(bins=50, figsize=(20,15))
         plt.show()
```

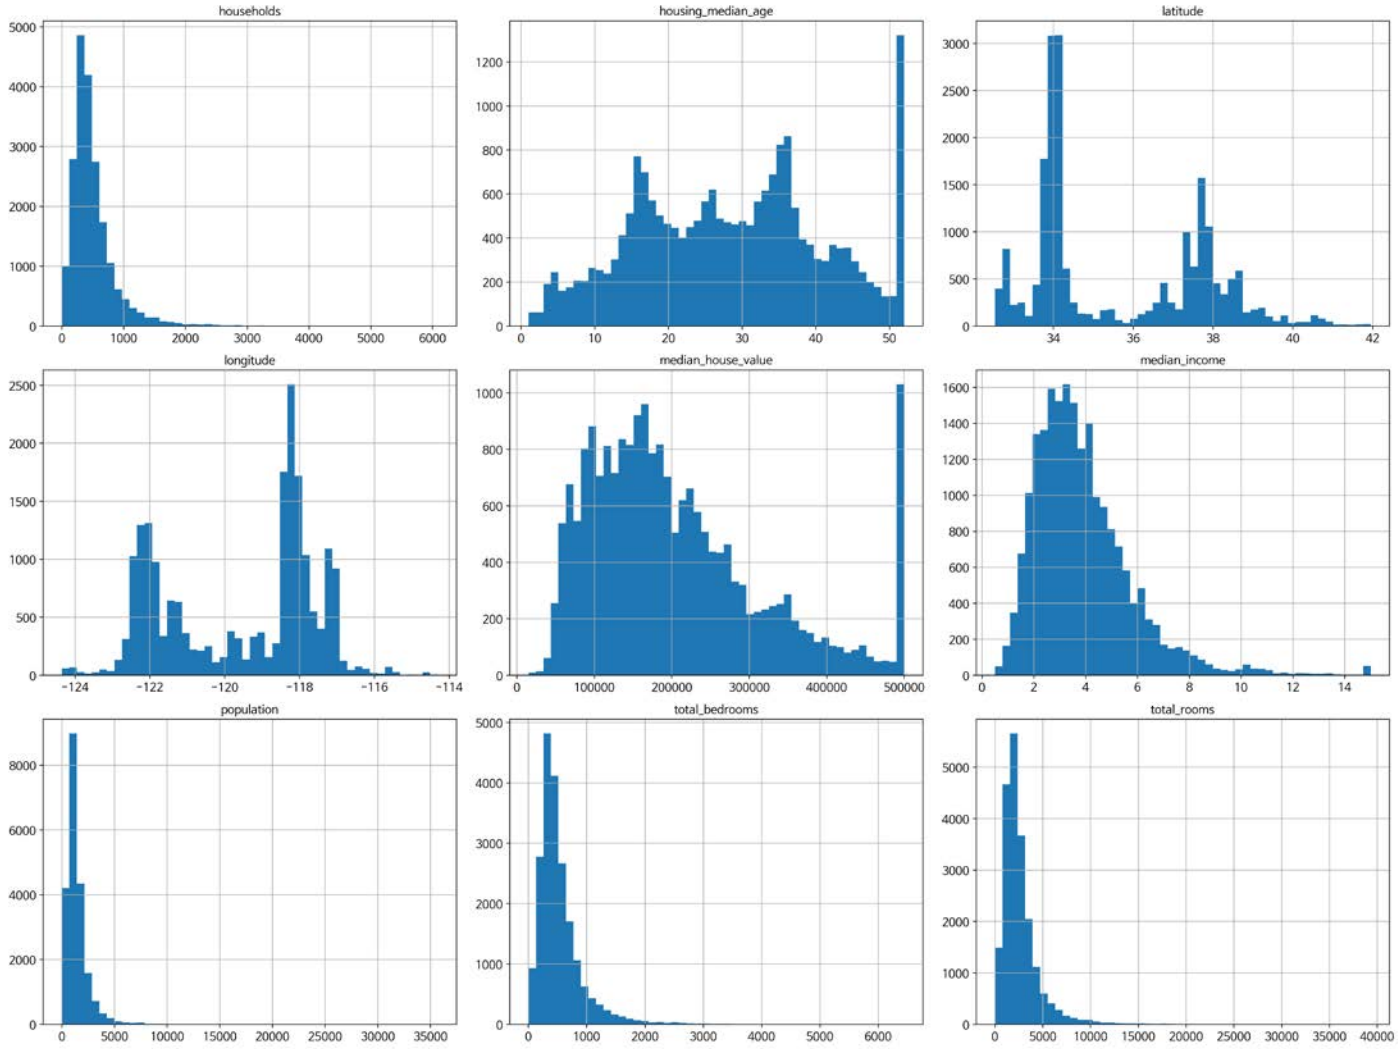

2.3.4 테스트 세트 만들기

- **데이터로부터 테스트 세트 분리**
  - 전체 데이터에서 너무 많은 직관을 얻으면 과대적합된 모델이 생성될 가능성이 있음 (data snooping 편향)
- **무작위로 샘플을 선택해서 데이터셋의 20% 정도 분리**

- **프로그램 재실행 시 이전의 데이터셋 불러와야...**
  - 이전 세트 저장 후 불러오기
  - 동일한 난수 인덱스 생성하기
- **데이터셋 업데이트 후에도 적용 가능해야...**

→ **고유식별자(예: ID)를 사용하여 테스트 세트로 결정**

scikit-learn 테스트 세트 분리함수

- 사이킷런 train_test_split() 함수
  - 난수 초기값 지정 가능
  - 동일 인덱스 기반 분리 가능

여러개의 배열을 넣을 수 있습니다
(파이썬 리스트, 넘파이, 판다스 데이터프레임)

train_size도 지정할 수 있습니다

```
from sklearn.model_selection import train_test_split

train_set, test_set = train_test_split(housing, test_size=0.2, random_state=42)
```

```
test_set.head()
```

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	median_house_value	ocean_proximit
20046	-119.01	36.06	25.0	1505.0	NaN	1392.0	359.0	1.6812	47700.0	INLANI
3024	-119.46	35.14	30.0	2943.0	NaN	1565.0	584.0	2.5313	45800.0	INLANI
15663	-122.44	37.80	52.0	3830.0	NaN	1310.0	963.0	3.4801	500001.0	NEAR BA
20484	-118.72	34.28	17.0	3051.0	NaN	1705.0	495.0	5.7376	218600.0	<1H OCEAI
9814	-121.93	36.62	34.0	2351.0	NaN	1063.0	428.0	3.7250	278000.0	NEAR OCEAI

샘플링 편향

- **계층적 샘플링**
  - 샘플에서도 전체 비율 유지해야 함

- **중간 주택 가격 예측 시 중간 소득이 중요**
  - 소득 카테고리 특성 중요
  - 중간 소득 히스토그램 : 대부분 $20,000~$50,000 / 일부 $60,000 이상
  - 계층별로 데이터셋에 충분한 샘플수 필요

소득 카테고리 “income_cat”

- 소득 카테고리 개수 제한 : 1.5로 나눔
- 5이상은 5로 레이블

```
import numpy as np
housing["income_cat"] = np.ceil(housing["median_income"] / 1.5)
housing["income_cat"].where(housing["income_cat"] < 5, 5.0, inplace=True)
```

```
housing["median_income"].hist()
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x8eb72b0>
```

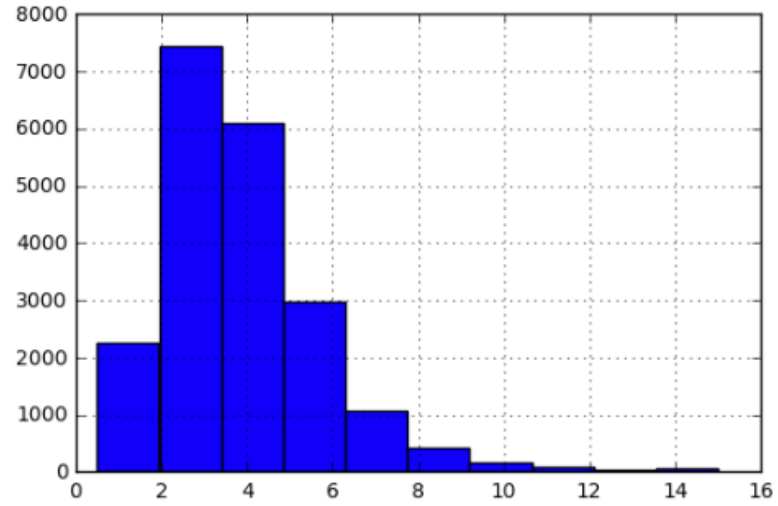


```
housing["income_cat"].hist()
```

```
<matplotlib.axes._subplots.AxesSubplot at 0x678b9d0>
```

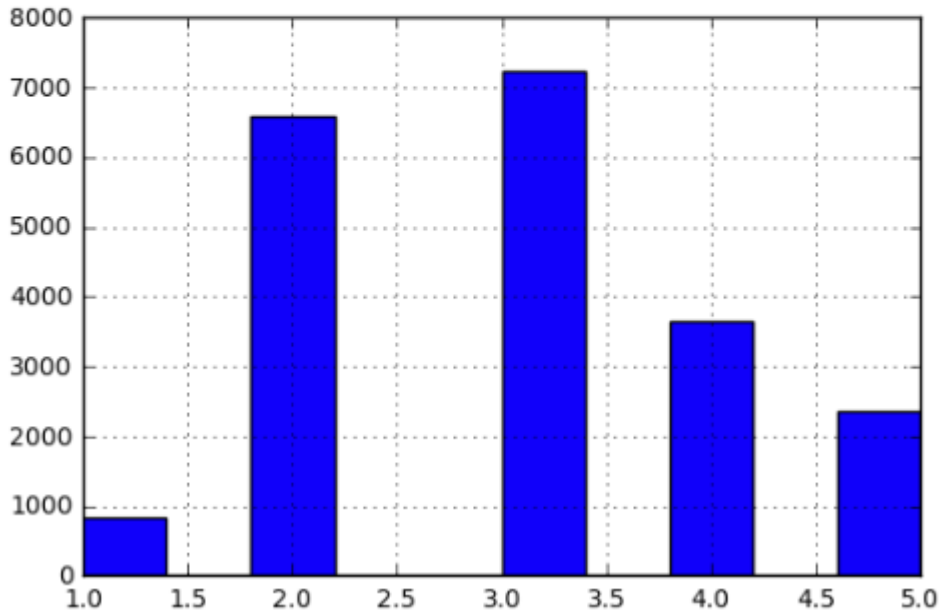

소득 카테고리 기반 계층 샘플링

- **scikit-learn의 StratifiedShuffleSplit**
  - StratifiedKFold의 계층 샘플링 + ShuffleSplit의 랜덤 샘플링
  - test_size와 train_size 매개변수 합을 1이하로 지정 가능

In [22]:
```
from sklearn.model_selection import StratifiedShuffleSplit

split = StratifiedShuffleSplit(n_splits=1, test_size=0.2, random_state=42)
for train_index, test_index in split.split(housing, housing["income_cat"]):
    strat_train_set = housing.loc[train_index]
    strat_test_set = housing.loc[test_index]
```

In [23]:
```
housing["income_cat"].value_counts() / len(housing)
```

Out[23]:
```
3.0    0.350581
2.0    0.318847
4.0    0.176308
5.0    0.114438
1.0    0.039826
Name: income_cat, dtype: float64
```

계층 샘플링 vs. 랜덤 샘플링 비교

- 계층샘플링 : StratifiedShuffleSplit
- 랜덤샘플링 : train_test_split

	Overall	Stratified	Random	Rand. %error	Strat. %error
1.0	0.039826	0.039729	0.040213	0.973236	-0.243309
2.0	0.318847	0.318798	0.324370	1.732260	-0.015195
3.0	0.350581	0.350533	0.358527	2.266446	-0.013820
4.0	0.176308	0.176357	0.167393	-5.056334	0.027480
5.0	0.114438	0.114583	0.109496	-4.318374	0.127011

- 샘플링 후 “income_cat” 특성 삭제

```
for set_ in (strat_train_set, strat_test_set):
    set_.drop("income_cat", axis=1, inplace=True)
```

2.4 데이터 이해를 위한 탐색과 시각화

- **train_set 복사본 생성 후 사용**

```
housing = strat_train_set.copy()
```

- **2.4.1 지리적 데이터 시각화**
  - 모든 구역 산점도

```
In [26]: housing.plot(kind="scatter", x="longitude", y="latitude")
Out[26]: <matplotlib.axes._subplots.AxesSubplot at 0xad2f250>
```

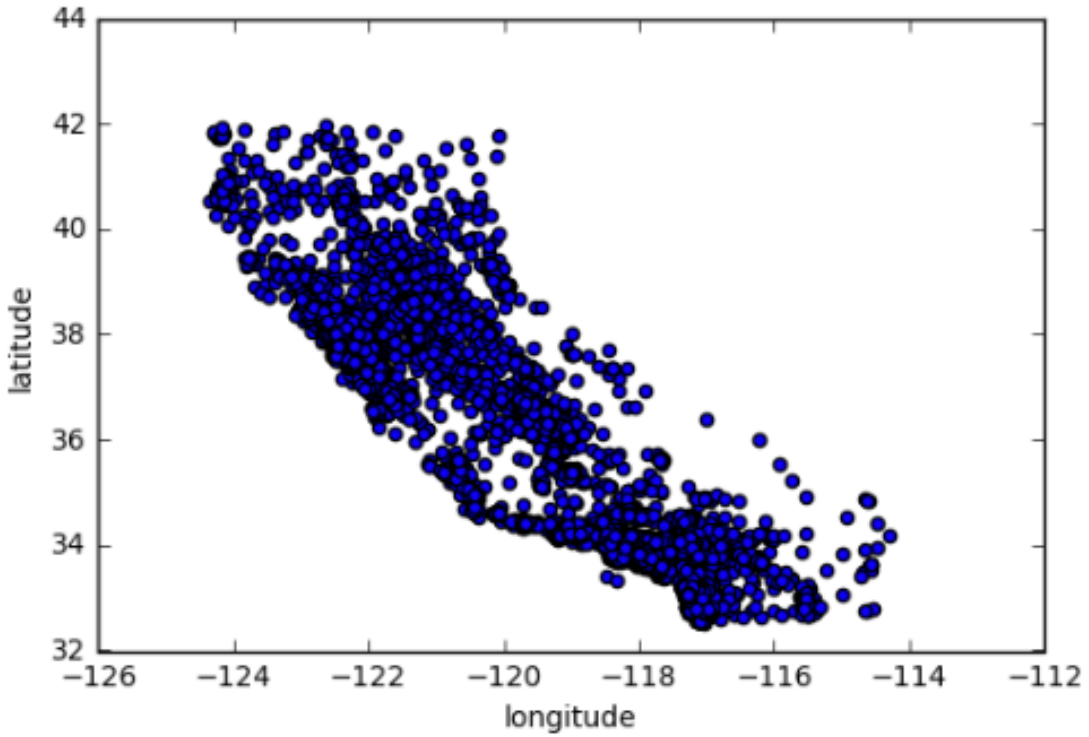

지리적 데이터 시각화

- 데이터 포인트가 밀집된 영역을 잘 보기 위해...
  - alpha option = 0.1

```
In [27]: housing.plot(kind="scatter", x="longitude", y="latitude", alpha=0.1)
Out[27]: <matplotlib.axes._subplots.AxesSubplot at 0xad73270>
```

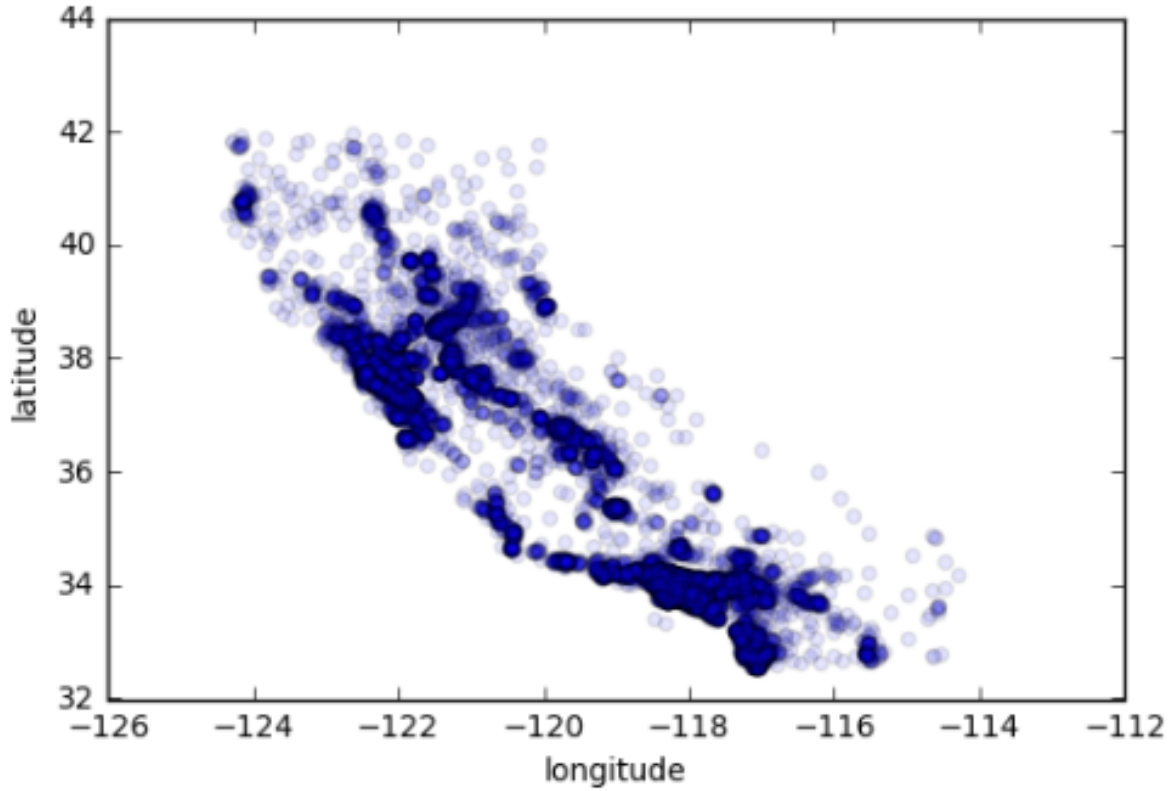

지리적 데이터 시각화

- **캘리포니아 주택 가격**
  - 원의 반지름 : 구역의 인구 (s)
  - 색깔 : 가격 (c)

```
In [28]: housing.plot(kind="scatter", x="longitude", y="latitude", alpha=0.4,
         s=housing["population"]/100, label="population", figsize=(10,7),
         c="median_house_value", cmap=plt.get_cmap("jet"), colorbar=True, sharex=False
         )
         plt.legend()

Out[28]: <matplotlib.legend.Legend at 0xa241ddd0>
```

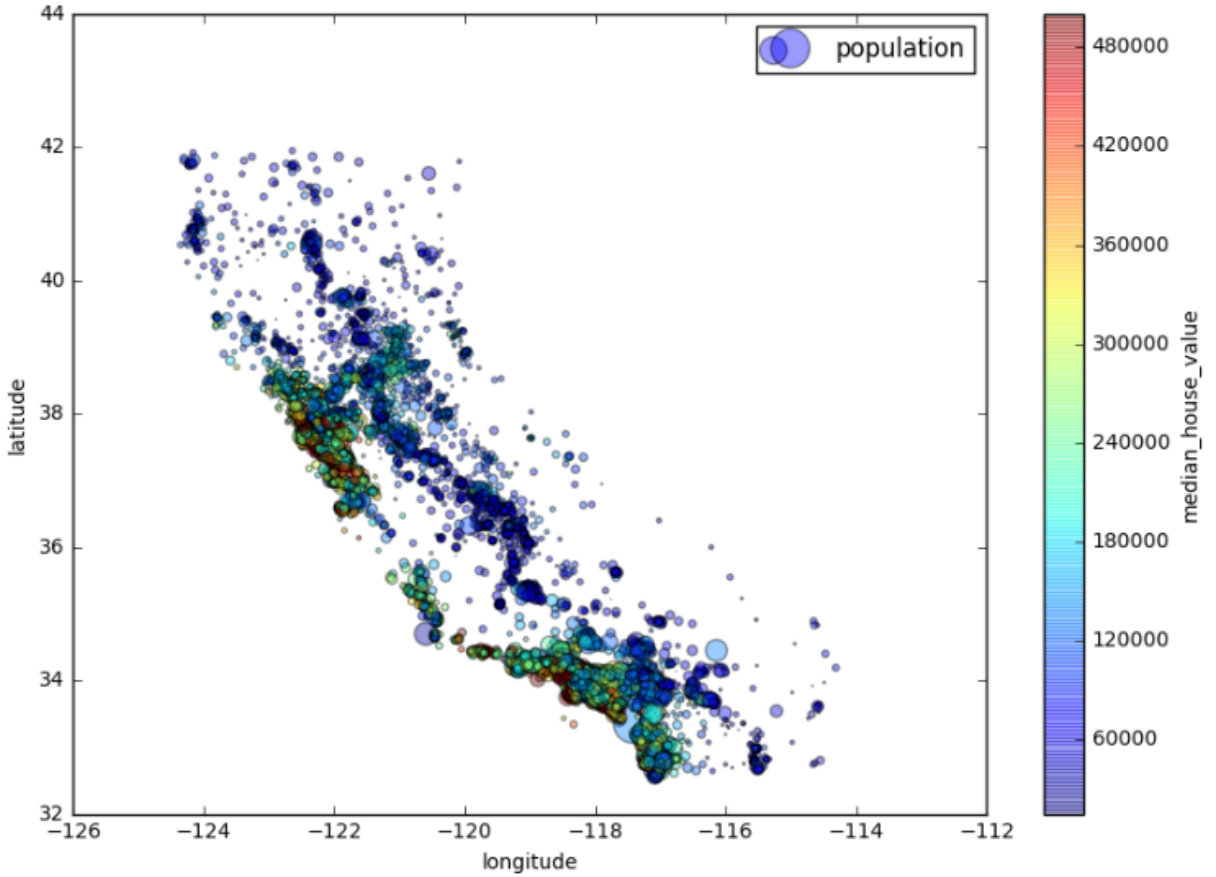

2.4.2 상관관계 조사

- **표준 상관계수 (standard correlation coefficient)**
  - Pearson's *r*
  - corr() 함수 이용

```
In [29]: corr_matrix = housing.corr()
         corr_matrix["median_house_value"].sort_values(ascending=False)
```

```
Out[29]: median_house_value    1.000000
         median_income         0.687160
         total_rooms           0.135097
         housing_median_age    0.114110
         households            0.064506
         total_bedrooms        0.047689
         population           -0.026920
         longitude            -0.047432
         latitude             -0.142724
         Name: median_house_value, dtype: float64
```

  - 상관관계 범위 : -1 ~ 1
  - 1에 가까우면 강한 양의 상관관계
    - 예) 중간 소득이 올라갈 때 주택 가격 증가
  - -1에 가까우면 강한 음의 상관관계
    - 예) 위도가 커질수록(북쪽) 주택 가격이 조금씩 감소
  - 0에 가까우면 선형적인 상관관계 없음

표준상관계수 그래프

- 중간 주택 가격과 상관 관계가 높아 보이는 특성 4개

In [22]:
```
from pandas.plotting import scatter_matrix

attributes = ["median_house_value", "median_income", "total_rooms", "housing_median_age"]
scatter_matrix(housing[attributes], figsize=(12, 8))
```

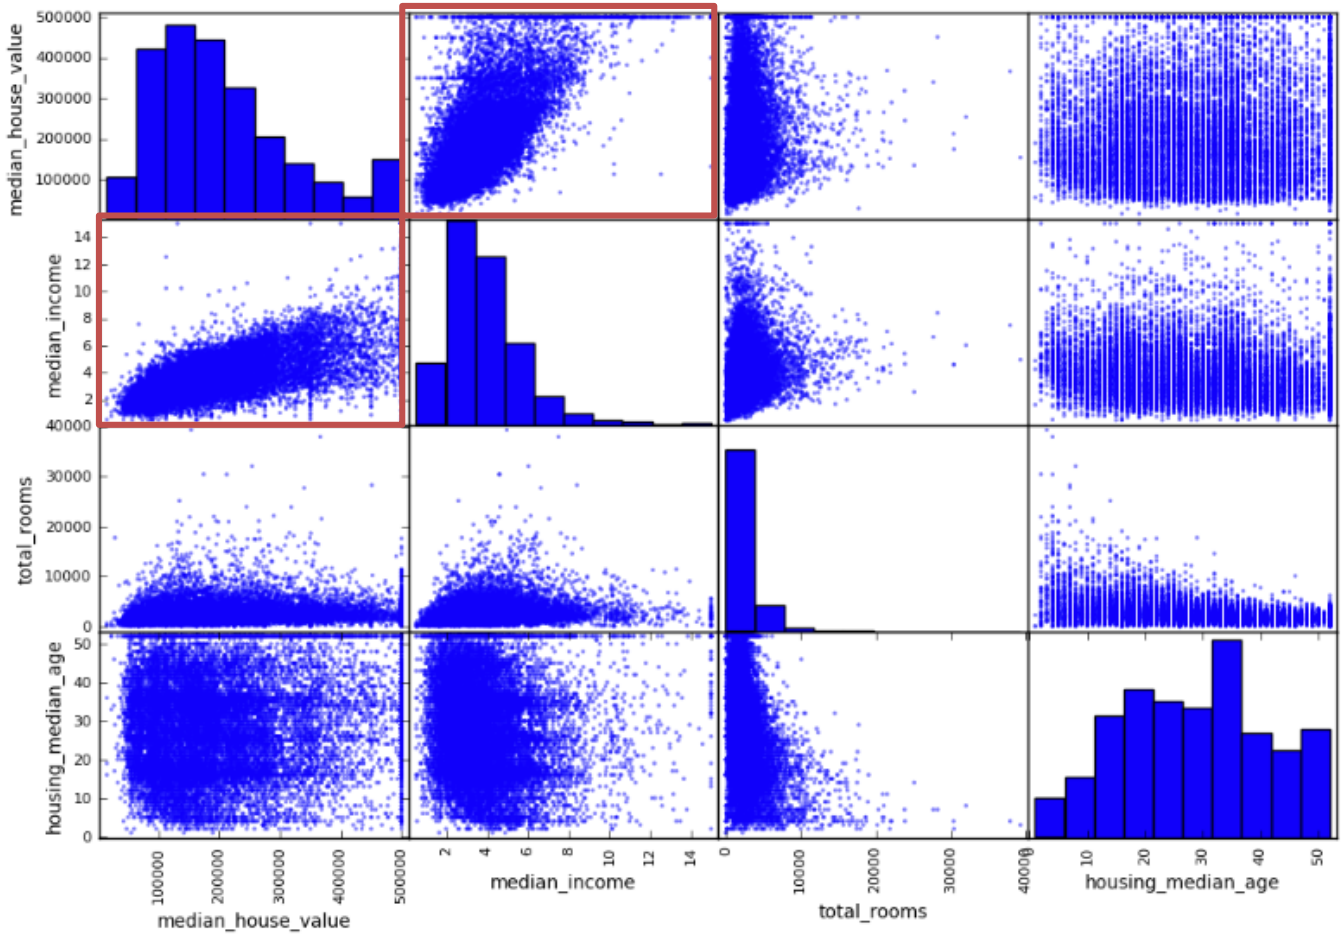

중간 소득 vs. 중간 주택 가격

```
In [23]: housing.plot(kind="scatter", x="median_income", y="median_house_value", alpha=0.1)
Out[23]: <matplotlib.axes._subplots.AxesSubplot at 0xc0e7bd0>
```

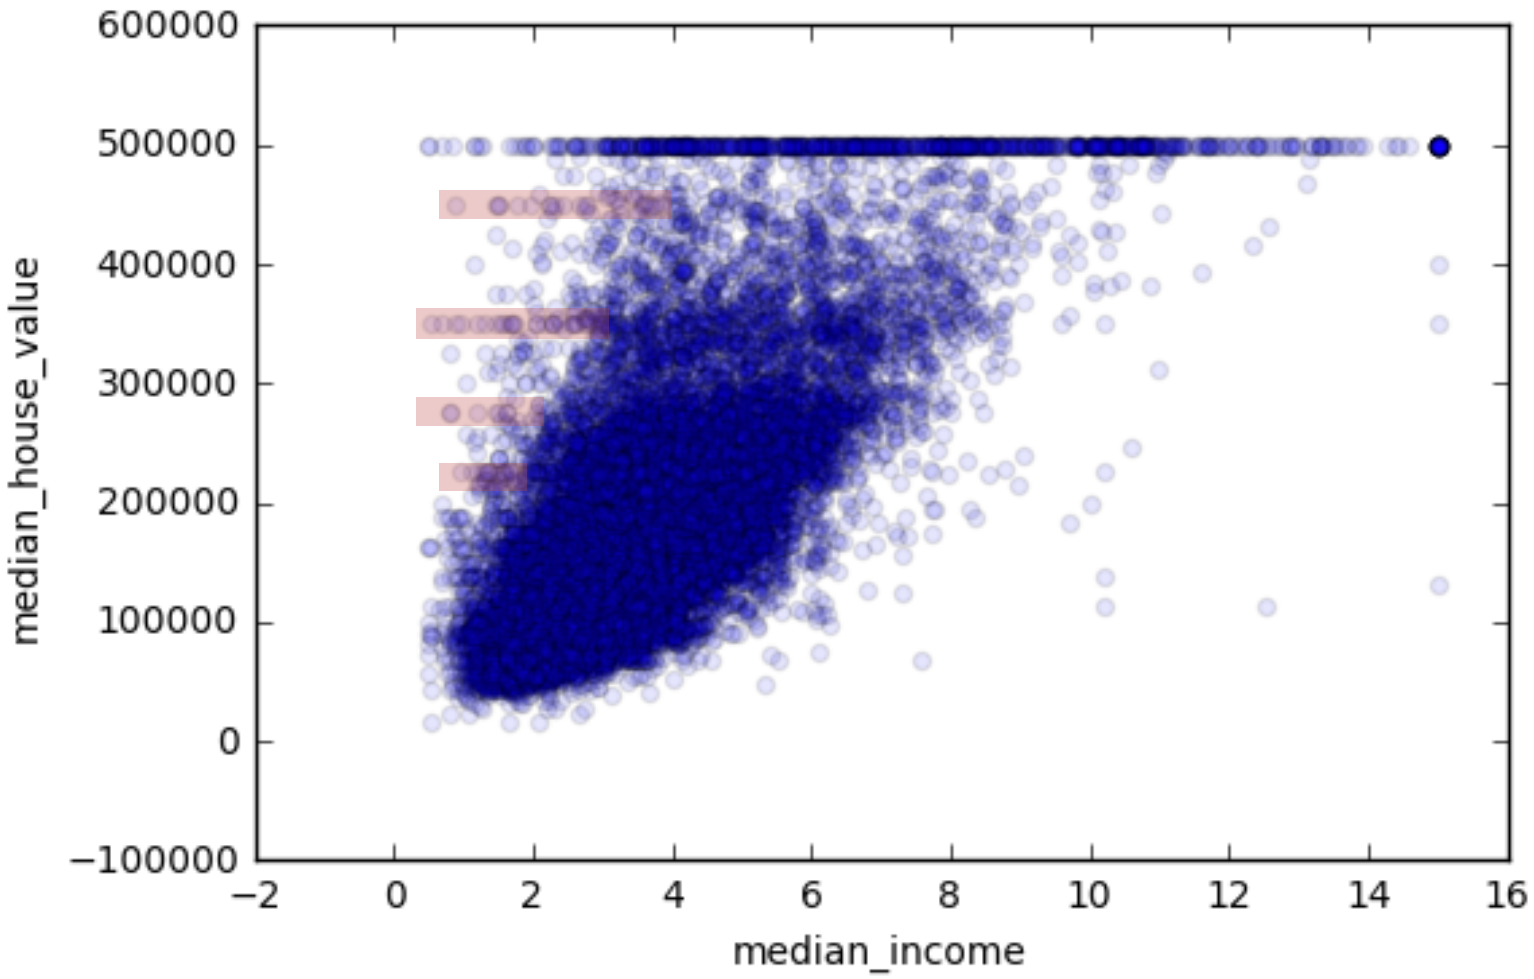

2.4.3 특성 조합

- **머신러닝 알고리즘 적용 전 확인**
  - 이상한 데이터 확인 → data refining 필요
  - 상관관계 확인
  - 여러 특성 조합 시도
    - 예) 방 개수 – 가구수 (실제로 필요한 정보 : 가구당 방 개수)
    - 예) 침대 개수 보다는 방 개수와 비교가 더 나음
    - 예) 가구 당 인원

In [24]:
```
housing["rooms_per_household"] = housing["total_rooms"]/housing["households"]
housing["bedrooms_per_room"] = housing["total_bedrooms"]/housing["total_rooms"]
housing["population_per_household"]=housing["population"]/housing["households"]

corr_matrix = housing.corr()
corr_matrix["median_house_value"].sort_values(ascending=False)
```

Out[24]:
```
median_house_value          1.000000
median_income               0.687160
rooms_per_household         0.146285
total_rooms                 0.135097
housing_median_age          0.114110
households                  0.064506
total_bedrooms              0.047689
population_per_household   -0.021985
population                 -0.026920
longitude                  -0.047432
latitude                   -0.142724
bedrooms_per_room          -0.259984
Name: median_house_value, dtype: float64
```

- **반복적으로 탐색**
- **프로토타입 생성→ 실행→결과분석→ 다시 탐색**

2.5 머신러닝 알고리즘을 위한 데이터 준비

- **데이터 준비 자동화**
  - 데이터 변환 손쉽게 반복 (예: 다음번에 새로운 데이터셋 사용 시)
  - 다른 프로젝트에 재사용 가능 변환 라이브러리 구축
  - 론칭 후 새 데이터에 적용 시 사용
  - 데이터 변화 쉽게 시도, 최적의 조합을 찾는데 편리

- **예측 변수와 레이블 분리**
  - 레이블 : 중간 주택 가격 해당열 (axis=1)

```
housing = strat_train_set.drop("median_house_value", axis=1) # 훈련 세트를 위해 레이블 삭제
housing_labels = strat_train_set["median_house_value"].copy()
```

```
housing.head() # 레이블 제거된 데이터
```

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	ocean_proximity
17606	-121.89	37.29	38.0	1568.0	351.0	710.0	339.0	2.7042	<1H OCEAN
18632	-121.93	37.05	14.0	679.0	108.0	306.0	113.0	6.4214	<1H OCEAN
14650	-117.20	32.77	31.0	1952.0	471.0	936.0	462.0	2.8621	NEAR OCEAN
3230	-119.61	36.31	25.0	1847.0	371.0	1460.0	353.0	1.8839	INLAND
3555	-118.59	34.23	17.0	6592.0	1525.0	4459.0	1463.0	3.0347	<1H OCEAN

```
housing_labels.head() # 레이블 데이터
```

```
17606     286600.0
18632     340600.0
14650     196900.0
3230       46300.0
3555      254500.0
Name: median_house_value, dtype: float64
```

2.5.1 데이터 정제

◆ 누락된 특성 처리

- 예) total_bedrooms

```
sample_incomplete_rows = housing[housing.isnull().any(axis=1)].head()
sample_incomplete_rows
```

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	ocean
4629	-118.30	34.07	18.0	3759.0	NaN	3296.0	1462.0	2.2708	
6068	-117.86	34.01	16.0	4632.0	NaN	3038.0	727.0	5.1762	
17923	-121.97	37.35	30.0	1955.0	NaN	999.0	386.0	4.6328	
13656	-117.30	34.05	6.0	2155.0	NaN	1039.0	391.0	1.6675	
19252	-122.79	38.48	7.0	6837.0	NaN	3468.0	1405.0	3.1662	

- 옵션 1: 해당 구역 제거
- 옵션 2: 전체 특성 삭제
- 옵션 3: 어떤 값을 채우기 (0, 평균, 중간값 등)

```
sample_incomplete_rows.dropna(subset=["total_bedrooms"])    # 옵션 1
```

```
sample_incomplete_rows.drop("total_bedrooms", axis=1)       # 옵션 2
```

```
median = housing["total_bedrooms"].median()
sample_incomplete_rows["total_bedrooms"].fillna(median, inplace=True) # 옵션 3
```

2.5.1 데이터 정제

- **scikit-learn Imputer 함수 : 누락된 값 처리**
  - → 0.22 버전 이후 “sklearn.impute.SimpleImputer”클래스로 변경

```
#from sklearn.preprocessing import Imputer
from sklearn.impute import SimpleImputer

imputer = SimpleImputer(strategy="median")
```

  - 중간값은 수치형 특성에서만 계산 가능. 텍스트 특성 제외 복사본 생성
  - fit() 메서드를 사용해 훈련 데이터에 적용

```
housing_num = housing.drop('ocean_proximity', axis=1)
# 다른 방법: housing_num = housing.select_dtypes(include=[np.number])
```

```
imputer.fit(housing_num)
```

```
SimpleImputer(add_indicator=False, copy=True, fill_value=None,
              missing_values=nan, strategy='median', verbose=0)
```

  - imputer는 결과를 객체의 statistics_ 속성에 저장 → 데이터 확인

```
imputer.statistics_
```

```
array([-118.51  ,   34.26  ,   29.    , 2119.5   ,  433.    , 1164.    ,
        408.    ,    3.5409])
```

각 특성의 중간 값이 수동으로 계산한 것과 같은지 확인해 보세요:

```
housing_num.median().values
```

```
array([-118.51  ,   34.26  ,   29.    , 2119.5   ,  433.    , 1164.    ,
        408.    ,    3.5409])
```

2.5.1 데이터 정제

- 학습된 imputer 객체를 사용해 훈련 세트에서 누락된 값 → 학습한 중간값으로 변경
- 그 결과는 변형된 특성들이 있는 평범한 Numpy 배열
- 다시 pandas DataFrame으로 변경

```
X = imputer.transform(housing_num)
```

```
housing_tr = pd.DataFrame(X, columns=housing_num.columns,
                          index = list(housing.index.values))
```

```
housing_tr.loc[sample_incomplete_rows.index.values]
```

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income
4629	-118.30	34.07	18.0	3759.0	433.0	3296.0	1462.0	2.2708
6068	-117.86	34.01	16.0	4632.0	433.0	3038.0	727.0	5.1762
17923	-121.97	37.35	30.0	1955.0	433.0	999.0	386.0	4.6328
13656	-117.30	34.05	6.0	2155.0	433.0	1039.0	391.0	1.6675
19252	-122.79	38.48	7.0	6837.0	433.0	3468.0	1405.0	3.1662

2.5.2 텍스트와 범주형 특성 다루기

- **“ocean_proximity” 카테고리 텍스트 → 숫자로 변형**
  - 각 카테고리를 다른 정수값으로 매핑 : pandas의 factorize() 함수

```
In [37]: housing_cat = housing["ocean_proximity"]
         housing_cat.head(10)
```

```
Out[37]: 17606     <1H OCEAN
         18632     <1H OCEAN
         14650    NEAR OCEAN
         3230         INLAND
         3555      <1H OCEAN
         19480        INLAND
         8879      <1H OCEAN
         13685        INLAND
         4937      <1H OCEAN
         4861      <1H OCEAN
         Name: ocean_proximity, dtype: object
```

```
In [38]: housing_cat_encoded, housing_categories = housing_cat.factorize()
         housing_cat_encoded[:10]
```

```
Out[38]: array([0, 0, 1, 2, 0, 2, 0, 2, 0, 0], dtype=int32)
```

```
In [39]: housing_categories
```

```
Out[39]: Index(['<1H OCEAN', 'NEAR OCEAN', 'INLAND', 'NEAR BAY', 'ISLAND'], dtype='object')
```

  - one-hot encoding으로 변환 필요 (한 특성만 1이고, 나머지는 0)

scikit-learn OneHotEncoder

- 숫자로 된 범주형 값을 one-hot vector로 변환
- fit_transform() ← 2차원 배열 (reshape으로 2차원으로 변형)
- 출력 형태 : SciPy의 sparse matrix
  - '0'이 아닌 원소의 위치만 저장 (메모리 절약)

```
In [65]: from sklearn.preprocessing import OneHotEncoder

         encoder = OneHotEncoder(categories='auto')
         housing_cat_1hot = encoder.fit_transform(housing_cat_encoded.reshape(-1,1))
         housing_cat_1hot

Out[65]: <16512x5 sparse matrix of type '<class 'numpy.float64'>'
                with 16512 stored elements in Compressed Sparse Row format>
```

- numpy 배열로 변형 : toarray() 함수
- text category → num category → one-hot vector : CategoricalEncoder (0.2 이후 버전)

```
In [66]: housing_cat_1hot.toarray()

Out[66]: array([[1., 0., 0., 0., 0.],
                [1., 0., 0., 0., 0.],
                [0., 1., 0., 0., 0.],
                ...,
                [0., 0., 1., 0., 0.],
                [1., 0., 0., 0., 0.],
                [0., 0., 0., 1., 0.]])
```

2.5.3 나만의 변환기

- **scikit-learn은 유용한 변환기를 많이 제공**

- **나만의 변환기**
  - pipeline 클래스와 연계 가능
  - 파이썬 클래스 생성해서 사용
    - fit(), transform(), fit_transform() 함수
    - TransformerMixin 상속하면 fit_transform() 함수 제공됨
    - BaseEstimator 상속하면 get_params(), set_params() 함수 제공됨

2.5.3 나만의 변환기

◆ 조합 특성 추가 변환기 구현

In [48]:
```
from sklearn.base import BaseEstimator, TransformerMixin

# 컬럼 인덱스
rooms_ix, bedrooms_ix, population_ix, household_ix = 3, 4, 5, 6

class CombinedAttributesAdder(BaseEstimator, TransformerMixin):
    def __init__(self, add_bedrooms_per_room = True): # no *args or **kargs
        self.add_bedrooms_per_room = add_bedrooms_per_room
    def fit(self, X, y=None):
        return self  # nothing else to do
    def transform(self, X, y=None):
        rooms_per_household = X[:, rooms_ix] / X[:, household_ix]
        population_per_household = X[:, population_ix] / X[:, household_ix]
        if self.add_bedrooms_per_room:
            bedrooms_per_room = X[:, bedrooms_ix] / X[:, rooms_ix]
            return np.c_[X, rooms_per_household, population_per_household,
                         bedrooms_per_room]
        else:
            return np.c_[X, rooms_per_household, population_per_household]

attr_adder = CombinedAttributesAdder(add_bedrooms_per_room=False)
housing_extra_attribs = attr_adder.transform(housing.values)
```

In [49]:
```
housing_extra_attribs = pd.DataFrame(
    housing_extra_attribs,
    columns=list(housing.columns)+["rooms_per_household", "population_per_household"])
housing_extra_attribs.head()
```

Out[49]:

	longitude	latitude	housing_median_age	total_rooms	total_bedrooms	population	households	median_income	ocean_proximity	rooms_per
0	-121.89	37.29	38	1568	351	710	339	2.7042	<1H OCEAN	4.62537
1	-121.93	37.05	14	679	108	306	113	6.4214	<1H OCEAN	6.00885
2	-117.2	32.77	31	1952	471	936	462	2.8621	NEAR OCEAN	4.22511
3	-119.61	36.31	25	1847	371	1460	353	1.8839	INLAND	5.23229
4	-118.59	34.23	17	6592	1525	4459	1463	3.0347	<1H OCEAN	4.50581

2.5.4 특성 스케일링(feature scaling)

- **머신러닝 알고리즘은 입력 숫자 특성들의 scale이 많이 다르면 잘 작동하지 않음**
  - 예) 전체 방 개수 범위 6~39,320 / 중간소득범위 0~15
- **특성의 범위를 같도록...**
  - min-max scaling : 정규화 (normalization)
    - 0~1 범위에 들도록 값 이동 및 스케일 조정
    - 데이터-최소값 / 최대값-최소값
    - scikit-learn MinMaxScaler 변환기
  - 표준화 (standardization)
    - 평균을 뺀 후, 표준편차로 나누어 결과 분포의 분산이 1이 되도록 함
    - scikit-learn StandardScaler 변환기

$\frac{x - \bar{x}}{\sigma}$ 표준점수, z-점수: 평균 0, 분산 1

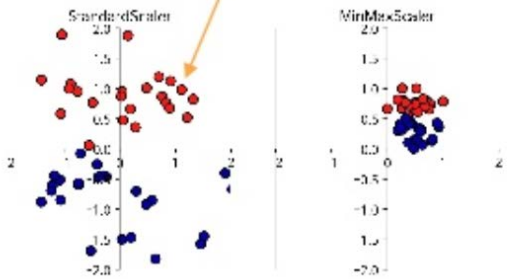

$\frac{x - x_{min}}{x_{max} - x_{min}}$

모든 특성이
0과 1사이에 위치
이상치에 민감

2.5.5 변환 파이프라인

- **Pipeline 클래스**
  - scikit-learn에서 연속된 변환을 순서대로 처리
- **숫자 특성 처리 파이프라인**

```
from sklearn.pipeline import Pipeline
from sklearn.preprocessing import StandardScaler

num_pipeline = Pipeline([
        ('imputer', SimpleImputer(strategy="median")),
        ('attribs_adder', CombinedAttributesAdder()),
        ('std_scaler', StandardScaler()),
    ])

housing_num_tr = num_pipeline.fit_transform(housing_num)
```

```
housing_num_tr
```

```
array([[-1.15604281,  0.77194962,  0.74333089, ..., -0.31205452,
        -0.08649871,  0.15531753],
       [-1.17602483,  0.6596948 , -1.1653172 , ...,  0.21768338,
        -0.03353391, -0.83628902],
       [ 1.18684903, -1.34218285,  0.18664186, ..., -0.46531516,
        -0.09240499,  0.4222004 ],
       ...,
       [ 1.58648943, -0.72478134, -1.56295222, ...,  0.3469342 ,
        -0.03055414, -0.52177644],
       [ 0.78221312, -0.85106801,  0.18664186, ...,  0.02499488,
         0.06150916, -0.30340741],
       [-1.43579109,  0.99645926,  1.85670895, ..., -0.22852947,
        -0.09586294,  0.10180567]])
```

pandas의 dataframe 처리하는 변환기 작성

- DataFrameSelector 클래스 : 나머지는 버리고, 필요한 특성을 선택하여 데이터프레임을 numpy 배열로 변경 (수치형만 다루는 파이프라인)

```
from sklearn.base import BaseEstimator, TransformerMixin

# 사이킷런이 DataFrame을 바로 사용하지 못하므로
# 수치형이나 범주형 컬럼을 선택하는 클래스를 만듭니다.
class DataFrameSelector(BaseEstimator, TransformerMixin):
    def __init__(self, attribute_names):
        self.attribute_names = attribute_names
    def fit(self, X, y=None):
        return self
    def transform(self, X):
        return X[self.attribute_names].values
```

```
num_attribs = list(housing_num)
cat_attribs = ["ocean_proximity"]

num_pipeline = Pipeline([
        ('selector', DataFrameSelector(num_attribs)),
        ('imputer', SimpleImputer(strategy="median")),
        ('attribs_adder', CombinedAttributesAdder()),
        ('std_scaler', StandardScaler()),
    ])

cat_pipeline = Pipeline([
        ('selector', DataFrameSelector(cat_attribs)),
        ('cat_encoder', CategoricalEncoder(encoding="onehot-dense")),
    ])
```

- 수치형 파이프라인 / 범주형 파이프라인

◆ 두 파이프라인 연결

사이킷런 0.20 버전에 추가된 `ColumnTransformer`로 만든 `full_pipline`을 사용합니다:

```
# from sklearn.pipeline import FeatureUnion

# full_pipeline = FeatureUnion(transformer_list=[
#         ("num_pipeline", num_pipeline),
#         ("cat_pipeline", cat_pipeline),
#     ])
full_pipeline = ColumnTransformer([
        ("num_pipeline", num_pipeline, num_attribs),
        ("cat_encoder", OneHotEncoder(categories='auto'), cat_attribs),
    ])
```

```
housing_prepared = full_pipeline.fit_transform(housing)
housing_prepared
```

```
array([[-1.15604281,  0.77194962,  0.74333089, ...,  0.        ,
         0.        ,  0.        ],
       [-1.17602483,  0.6596948 , -1.1653172 , ...,  0.        ,
         0.        ,  0.        ],
       [ 1.18684903, -1.34218285,  0.18664186, ...,  0.        ,
         0.        ,  1.        ],
       ...,
       [ 1.58648943, -0.72478134, -1.56295222, ...,  0.        ,
         0.        ,  0.        ],
       [ 0.78221312, -0.85106801,  0.18664186, ...,  0.        ,
         0.        ,  0.        ],
       [-1.43579109,  0.99645926,  1.85670895, ...,  0.        ,
         1.        ,  0.        ]])
```

```
housing_prepared.shape
```

```
(16512, 16)
```

2.6 모델 선택과 훈련

◆ 2.6.1 훈련 세트에서 훈련하고 평가하기

◆ 모델선택1) 선형 회귀 모델

In [56]:
```
from sklearn.linear_model import LinearRegression

lin_reg = LinearRegression()
lin_reg.fit(housing_prepared, housing_labels)
```

Out[56]:
```
LinearRegression(copy_X=True, fit_intercept=True, n_jobs=1, normalize=False)
```

- 샘플에 적용 확인

In [57]:
```
some_data = housing.iloc[:5]
some_labels = housing_labels.iloc[:5]
some_data_prepared = full_pipeline.transform(some_data)
```

In [58]:
```
print("예측: ", lin_reg.predict(some_data_prepared))
```

```
예측:  [ 210644.60459286  317768.80697211  210956.43331178   59218.98886849
  189747.55849879]
```

In [59]:
```
print("레이블: ", list(some_labels))
```

```
레이블:  [286600.0, 340600.0, 196900.0, 46300.0, 254500.0]
```

RMSE 측정

- **scikit-learn의 mean_square_error() 함수 사용**

```
In [61]: from sklearn.metrics import mean_squared_error
         housing_predictions = lin_reg.predict(housing_prepared)
         lin_mse = mean_squared_error(housing_labels, housing_predictions)
         lin_rmse = np.sqrt(lin_mse)
         lin_rmse
Out[61]: 68628.198198489234

In [62]: housing_labels.mean(), housing_labels.std()
Out[62]: (206990.9207243217, 115703.01483031521)

In [63]: lin_reg.score(housing_prepared, housing_labels)
Out[63]: 0.64816248428044276
```

- RMSE 예측 오차 : $68,628 → 낮을수록 좋음
- score 높을수록 좋음 : 0.648... → 과소적합 (underfitting)
- 모델이 train data에 과소적합된 사례
  - 모델이 너무 단순해서 데이터의 내재된 구조를 학습하지 못할 때
  - 해결방법 1) 파라미터가 더 많은 **강력한 모델** 선택 → **먼저 시도**
  - 해결방법 2) 학습 알고리즘에 더 좋은 특성 제공
  - 해결방법 3) 모델 규제 감소 (→ 이 예제에서는 규제 사용 안함)

모델 선택2) 결정 트리

DesionTreeRegressor 모델 훈련

```
In [64]: from sklearn.tree import DecisionTreeRegressor

         tree_reg = DecisionTreeRegressor()
         tree_reg.fit(housing_prepared, housing_labels)

Out[64]: DecisionTreeRegressor(criterion='mse', max_depth=None, max_features=None,
                    max_leaf_nodes=None, min_impurity_decrease=0.0,
                    min_impurity_split=None, min_samples_leaf=1,
                    min_samples_split=2, min_weight_fraction_leaf=0.0,
                    presort=False, random_state=None, splitter='best')
```

- 훈련 세트로 평가

```
In [65]: housing_predictions = tree_reg.predict(housing_prepared)
         tree_mse = mean_squared_error(housing_labels, housing_predictions)
         tree_rmse = np.sqrt(tree_mse)
         tree_rmse

Out[65]: 0.0

In [66]: tree_reg.score(housing_prepared, housing_predictions)

Out[66]: 1.0
```

- 오차 = 0.0
- score = 1.0 → 과대적합 (overfitting)
  - model이 train data에 너무 잘 맞지만, 일반성이 떨어짐

2.6.2 교차 검증을 사용한 평가

- **train set 중 일부를 사용하여 검증에 사용**
- **scikit-learn cross-validation (k-fold cross-validation)**
  - fold : subset

  - 훈련 세트를 10개의 폴드(서브셋)로 분할 (무작위)
  - 결정트리모델을 10번 훈련하고 평가
    (매번 다른 폴드를 선택해서 평가, 나머지 9개 폴드는 훈련에 사용)
  - **결과)** 10개의 평가 점수가 담긴 배열

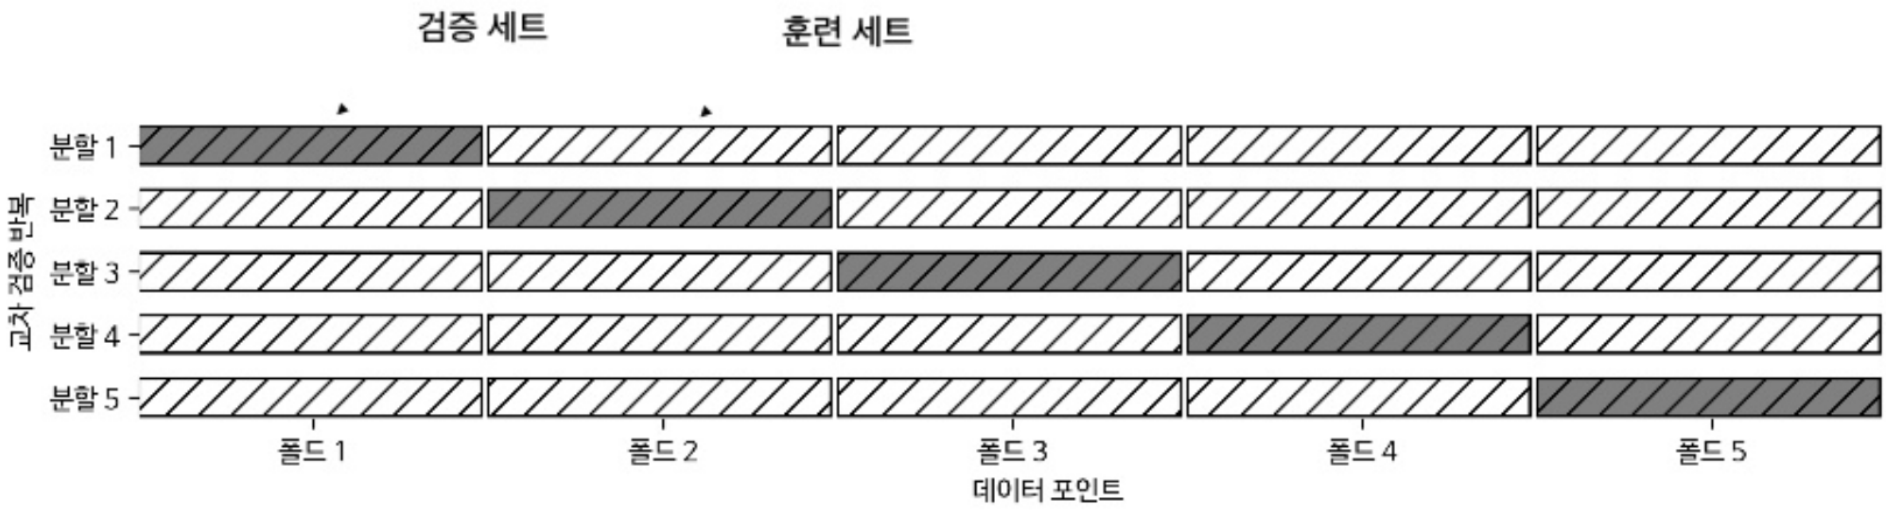

◆ 결정 트리 검증 결과

In [69]:

```
from sklearn.model_selection import cross_val_score
scores = cross_val_score(tree_reg, housing_prepared, housing_labels,
                         scoring="neg_mean_squared_error", cv=10)
tree_rmse_scores = np.sqrt(-scores)

def display_scores(scores):
    print("Scores:", scores)
    print("Mean:", scores.mean())
    print("Standard deviation:", scores.std())

display_scores(tree_rmse_scores)
```

```
Scores: [ 68109.06259568  66943.63356662  71594.75323241  68942.80518278
  70918.0003004   75081.18897418  70626.41498532  71763.18783985
  78783.35316833  70158.1998105 ]
Mean: 71292.0599656
Standard deviation: 3274.42334379
```

- 평균 : 71,292
- 표준편차 : 3,274

◆ 회귀 모델 검증 결과

In [70]:

```
lin_scores = cross_val_score(lin_reg, housing_prepared, housing_labels,
                             scoring="neg_mean_squared_error", cv=10)

lin_rmse_scores = np.sqrt(-lin_scores)
display_scores(lin_rmse_scores)
```

```
Scores: [ 66782.73843989  66960.118071    70347.95244419  74739.57052552
  68031.13388938  71193.84183426  64969.63056405  68281.61137997
  71552.91566558  67665.10082067]
Mean: 69052.4613635
Standard deviation: 2731.6740018
```

- 평균 : 69,052
- 표준편차 : 2,731

RandomForestRegressor

- **무작위로 특성을 선택해서 많은 DecisionTree를 생성하고, 그 예측을 평균 냄**
  - **앙상블 학습** : 여러 다른 모델을 모아서 하나의 모델을 만드는 것
  - 머신러닝 알고리즘 성능 극대화 방법 중 하나

In [71]:
```
from sklearn.ensemble import RandomForestRegressor
forest_reg = RandomForestRegressor()
forest_reg.fit(housing_prepared, housing_labels)
```

Out[71]:
```
RandomForestRegressor(bootstrap=True, criterion='mse', max_depth=None,
           max_features='auto', max_leaf_nodes=None,
           min_impurity_decrease=0.0, min_impurity_split=None,
           min_samples_leaf=1, min_samples_split=2,
           min_weight_fraction_leaf=0.0, n_estimators=10, n_jobs=1,
           oob_score=False, random_state=None, verbose=0, warm_start=False)
```

In [72]:
```
housing_predictions = forest_reg.predict(housing_prepared)
forest_mse = mean_squared_error(housing_labels, housing_predictions)
forest_rmse = np.sqrt(forest_mse)
forest_rmse
```

Out[72]:
```
22534.651251015624
```

In [73]:
```
from sklearn.model_selection import cross_val_score

forest_scores = cross_val_score(forest_reg, housing_prepared, housing_labels,
                                scoring="neg_mean_squared_error", cv=10)
forest_rmse_scores = np.sqrt(-forest_scores)
display_scores(forest_rmse_scores)
```

```
Scores: [ 53018.62573497  49748.6765257   51080.6823411   55480.57393783
  51220.62786958  55532.7434547   50918.77758198  50700.22329812
  55377.35557488  52712.46753021]
Mean: 52579.0753849
Standard deviation: 2087.4053737
```

2.7 모델 세부 튜닝

- 가능성 있는 2~5개 정도의 모델을 선정하여 저장해 두면 편리함
- 최적의 하이퍼파라미터를 찾아야 함

- 가장 단순한 방법 → 만족할만한 하이퍼파라미터 조합을 찾을 때까지 수동으로 조정

2.7.1 그리드 탐색

- **scikit-learn의 GridSearchCV 사용**
  - 탐색하고자 하는 하이퍼파라미터와 시도값 지정
  - 가능한 모든 하이퍼파라미터 조합에 대해 교차 검증을 사용해 평가

In [74]:
```
from sklearn.model_selection import GridSearchCV

param_grid = [
        {'n_estimators': [3, 10, 30], 'max_features': [2, 4, 6, 8]},
        {'bootstrap': [False], 'n_estimators': [3, 10], 'max_features': [2, 3, 4]},
    ]
forest_reg = RandomForestRegressor()

grid_search = GridSearchCV(forest_reg, param_grid, cv=5,
                           scoring='neg_mean_squared_error',
                           return_train_score=True)

grid_search.fit(housing_prepared, housing_labels)
```

Out[74]:
```
GridSearchCV(cv=5, error_score='raise',
       estimator=RandomForestRegressor(bootstrap=True, criterion='mse', max_depth=None,
           max_features='auto', max_leaf_nodes=None,
           min_impurity_decrease=0.0, min_impurity_split=None,
           min_samples_leaf=1, min_samples_split=2,
           min_weight_fraction_leaf=0.0, n_estimators=10, n_jobs=1,
           oob_score=False, random_state=None, verbose=0, warm_start=False),
       fit_params=None, iid=True, n_jobs=1,
       param_grid=[{'max_features': [2, 4, 6, 8], 'n_estimators': [3, 10, 30]}, {'bootstrap': [False], 'max_features': [2, 3, 4], 'n_estimat
ors': [3, 10]}],
       pre_dispatch='2*n_jobs', refit=True, return_train_score=True,
       scoring='neg_mean_squared_error', verbose=0)
```

In [75]:
```
grid_search.best_params_
```

Out[75]:
```
{'max_features': 6, 'n_estimators': 30}
```

In [76]:
```
grid_search.best_estimator_
```

Out[76]:
```
RandomForestRegressor(bootstrap=True, criterion='mse', max_depth=None,
           max_features=6, max_leaf_nodes=None, min_impurity_decrease=0.0,
           min_impurity_split=None, min_samples_leaf=1,
           min_samples_split=2, min_weight_fraction_leaf=0.0,
           n_estimators=30, n_jobs=1, oob_score=False, random_state=None,
           verbose=0, warm_start=False)
```

In [77]:
```
cvres = grid_search.cv_results_
for mean_score, params in zip(cvres["mean_test_score"], cvres["params"]):
    print(np.sqrt(-mean_score), params)
```

```
64223.2850771 {'max_features': 2, 'n_estimators': 3}
55407.8687859 {'max_features': 2, 'n_estimators': 10}
52932.3550944 {'max_features': 2, 'n_estimators': 30}
60222.8024295 {'max_features': 4, 'n_estimators': 3}
52951.7955765 {'max_features': 4, 'n_estimators': 10}
50280.7716783 {'max_features': 4, 'n_estimators': 30}
59048.4337212 {'max_features': 6, 'n_estimators': 3}
52588.478215 {'max_features': 6, 'n_estimators': 10}
50031.7461754 {'max_features': 6, 'n_estimators': 30}
58077.5052279 {'max_features': 8, 'n_estimators': 3}
51545.0350056 {'max_features': 8, 'n_estimators': 10}
50083.4490232 {'max_features': 8, 'n_estimators': 30}
63065.7241353 {'bootstrap': False, 'max_features': 2, 'n_estimators': 3}
54091.1788418 {'bootstrap': False, 'max_features': 2, 'n_estimators': 10}
59798.9622518 {'bootstrap': False, 'max_features': 3, 'n_estimators': 3}
52314.2649346 {'bootstrap': False, 'max_features': 3, 'n_estimators': 10}
59226.5630142 {'bootstrap': False, 'max_features': 4, 'n_estimators': 3}
51963.370483 {'bootstrap': False, 'max_features': 4, 'n_estimators': 10}
```

2.7.1 그리드 탐색

- 비교적 적은 수의 조합 탐구에 적합
- 가능한 모든 조합을 시도
- 하이퍼파라미터마다 몇 개의 값만 탐색

2.7.2 랜덤 탐색

- 탐색 공간이 커지면 랜덤 탐색 방식이 유용
- 각 반복마다 하이퍼파라미터에 임의의 수를 대입하여, 지정한 횟수만큼 평가
- 하이퍼파라미터마다 각기 다른 값 탐색
- 단순히 반복 횟수를 조절하는 것만으로 하이퍼파라미터 탐색에 투입할 컴퓨팅 자원 제어 가능

2.7.3 앙상블 방법

- 단일 모델을 연결하여 모델의 그룹으로 만듬
- 예) 결정 트리의 앙상블 → 랜덤 포레스트

2.7.2 랜덤 탐색

In [80]:
```
from sklearn.model_selection import RandomizedSearchCV
from scipy.stats import randint

param_distribs = {
        'n_estimators': randint(low=1, high=200),
        'max_features': randint(low=1, high=8),
    }

forest_reg = RandomForestRegressor(random_state=42)
rnd_search = RandomizedSearchCV(forest_reg, param_distributions=param_distribs,
                                n_iter=10, cv=5, scoring='neg_mean_squared_error',
                                random_state=42, n_jobs=-1)
rnd_search.fit(housing_prepared, housing_labels)
```

Out[80]:
```
RandomizedSearchCV(cv=5, error_score='raise',
          estimator=RandomForestRegressor(bootstrap=True, criterion='mse', max_depth=None,
           max_features='auto', max_leaf_nodes=None,
           min_impurity_decrease=0.0, min_impurity_split=None,
           min_samples_leaf=1, min_samples_split=2,
           min_weight_fraction_leaf=0.0, n_estimators=10, n_jobs=1,
           oob_score=False, random_state=42, verbose=0, warm_start=False),
          fit_params=None, iid=True, n_iter=10, n_jobs=-1,
          param_distributions={'max_features': <scipy.stats._distn_infrastructure.rv_frozen object at 0x0BEBE110>, 'n_estimators': <scipy.st
ats._distn_infrastructure.rv_frozen object at 0x0BEBE6F0>},
          pre_dispatch='2*n_jobs', random_state=42, refit=True,
          return_train_score=True, scoring='neg_mean_squared_error',
          verbose=0)
```

In [81]:
```
cvres = rnd_search.cv_results_
for mean_score, params in zip(cvres["mean_test_score"], cvres["params"]):
    print(np.sqrt(-mean_score), params)
```

```
49147.1524172 {'max_features': 7, 'n_estimators': 180}
51396.8768969 {'max_features': 5, 'n_estimators': 15}
50797.0573732 {'max_features': 3, 'n_estimators': 72}
50840.744514 {'max_features': 5, 'n_estimators': 21}
49276.1753033 {'max_features': 7, 'n_estimators': 122}
50775.4633168 {'max_features': 3, 'n_estimators': 75}
50681.383925 {'max_features': 3, 'n_estimators': 88}
49612.1525305 {'max_features': 5, 'n_estimators': 100}
50473.0175142 {'max_features': 3, 'n_estimators': 150}
64458.2538503 {'max_features': 5, 'n_estimators': 2}
```

테스트 세트 평가

- **마지막에 한번 수행**
  - test set → pridector, label 데이터
  - full pipeline 사용하여 데이터 변환 (transform())
  - test set에서 최종 모델 평가

```
In [82]: final_model = grid_search.best_estimator_

         X_test = strat_test_set.drop("median_house_value", axis=1)
         y_test = strat_test_set["median_house_value"].copy()

         X_test_prepared = full_pipeline.transform(X_test)

         final_predictions = final_model.predict(X_test_prepared)

         final_mse = mean_squared_error(y_test, final_predictions)
         final_rmse = np.sqrt(final_mse)
```

```
In [83]: final_rmse
Out[83]: 48403.473415816981
```

  - 최종 RMSE 오차 확인

2.8 론칭, 모니터링, 시스템 유지보수

- **전처리와 예측을 포함한 파이프라인**
  - preparation + linear model

```
In [84]: full_pipeline_with_predictor = Pipeline([
             ("preparation", full_pipeline),
             ("linear", LinearRegression())
         ])

         full_pipeline_with_predictor.fit(housing, housing_labels)
         full_pipeline_with_predictor.predict(some_data)

Out[84]: array([ 210644.60459286,  317768.80697211,  210956.43331178,
                  59218.98886849,  189747.55849879])
```

- **모델 저장**
  - 하이퍼파라미터, 모델 파라미터 모두 저장

```
In [85]: my_model = full_pipeline_with_predictor

In [86]: from sklearn.externals import joblib
         joblib.dump(my_model, "my_model.pkl") # DIFF
         #...
         my_model_loaded = joblib.load("my_model.pkl") # DIFF
```

- **론칭**
  - 실시간 성능 체크를 위한 모니터링 코드 개발
  - 분석가의 성능 평가 (예: 해당 분야의 전문가)
  - 입력 데이터 모니터링 코드 개발
  - 정기적 훈련을 위한 자동화

- **Future Chapters...**
  - 분류 (classification)
  - 모델 훈련 (model training)

Any Questions...
Just Ask!